Giải thích chi tiết 12 kỹ thuật LLM cho gợi ý tin tức

Mỗi kỹ thuật một trang: mã hóa bài, mã hóa người dùng, cách chấm điểm, siêu tham số, hàm mất mát, tham số được học

Người thực hiện: Nguyễn Nam Hán – 20252095M
Nguyễn Phúc Nguyên – 20261222M
Lê Văn Đức – 20261233M

GVHD: TS. Ngô Văn Linh

2026

Nội dung

1. Thành phần dùng chung: dữ liệu, bộ mã hóa đóng băng, cách huấn luyện reader
2. Bảng so sánh nhanh 12 kỹ thuật
3. H1 – H4b: lịch sử dạng văn bản, LoRA bộ mã hóa, kNN-RAG, GraphRAG
4. H5 – H8: User Tower LLM, LLM viết thêm, Semantic ID, late interaction
5. H9 – H12: LLM chấm điểm, reader theo ứng viên, đa sở thích, mở khóa encoder
6. Bảng tổng hợp tham số được huấn luyện, hàm mất mát và tối ưu

Thành phần dùng chung của mọi kỹ thuật

Dữ liệu	MIND-large: 104.151 bài; train 2.232.748 impression; validation = ngày cuối của train; test = `MINDlarge_dev` 376.471 impression. Mẫu huấn luyện (`train_core`) = (lịch sử, 1 bài click, 4 bài bỏ qua lấy mẫu trong cùng impression); toàn bộ 2.71 triệu mẫu.
Văn bản của bài	`ta` = `"title. abstract"` (tối đa 256 token); `cta` = `"Category: {cat}. Subcategory: {subcat}. title. abstract"`.
Bộ mã hóa đóng băng	BGE-small (384 chiều), BGE-large (1024, vector CLS), Qwen3-Embedding-0.6B (1024, token cuối), vector nối $\mathbf{e} = [\mathbf{e}_{\text{Qwen3}} \| \mathbf{e}_{\text{BGE}}]/\sqrt{2}$ (2048 chiều). Mọi vector được chuẩn hóa L2; mỗi bài mã hóa một lần, lưu thành bảng $\mathbf{E} \in \mathbb{R}^{N \times d}$.
Lịch sử đọc	50 bài click gần nhất, theo thứ tự thời gian (biến thể 100 / 200 bài ở bước F). Riêng các kỹ thuật "lịch sử dạng văn bản" (H1, H5) dùng 10 tiêu đề gần nhất.
Chọn mô hình	Mọi siêu tham số, epoch, trọng số chọn trên validation; tập test chỉ đo một lần. Độ đo chính: nDCG@10 (kèm AUC, MRR, nDCG@5, Cold AUC).
Reader chung	Dùng ở H3, H6, H10, H11, H12: đầu MLP hai tầng trên $\mathbf{E}$ rồi attention theo ứng viên (chi tiết ở trang H10). Loss: cross-entropy trên 1 bài click + 4 bài bỏ qua.
Nhãn kết quả	Số Δ nDCG@10 trong các trang sau lấy từ bộ slide kết quả; v7, v13 = MIND-small, v14 trở đi = MIND-large.

Bảng so sánh nhanh: mã hóa bài, mã hóa người dùng, điểm số, tham số học

Mã	Mã hóa bài (item)	Mã hóa người dùng (user)	Điểm $s(u, c)$	Tham số được học
H1	Qwen3-Emb vector bài (đóng băng)	Văn bản `Instruct + 10 tiêu đề` qua Qwen3-Emb, token cuối	cosine	không (bản có MLP: 2 đầu MLP residual)
H2	BGE-small + LoRA / DoRA, mã hóa lại toàn bộ bài	mean pooling 50 bài	cosine	LoRA q, v 12 lớp: 294.912 (DoRA 304.128)
H3	$\mathbf{e}_c + \beta\,\mathrm{Norm}(\sum_{j\in\mathcal{N}_k(c)} s_{cj}\mathbf{e}_j)$	mean pooling hoặc reader	cosine / reader	không (zero-shot); reader như H10
H4	vector gốc; thêm tâm cộng đồng	mean pooling + histogram cộng đồng	cosine $+\lambda\cdot$độ gần cộng đồng	không
H4b	như H4, tâm thay bằng vector câu tóm tắt LLM	như H4	như H4	không (LLM sinh, không huấn luyện)
H5	Qwen3-Emb vector bài (đóng băng)	LoRA-Qwen3 đọc `Instruct + 10 tiêu đề`, token cuối	cosine	LoRA 7 ma trận $\times$ 28 lớp: 10.092.544
H6	$\mathrm{Norm}(\mathbf{e}_c + \alpha\,\mathbf{e}_{\mathrm{exp}})$, $\mathbf{e}_{\mathrm{exp}} =$ vector đoạn LLM viết	mean pooling / LSE / reader	cosine / LSE / reader	không (zero-shot); reader như H10
H7	Mã 3 tầng RQ-KMeans (256 cụm/tầng)	chuỗi 30 $\times$ 3 token mã	log P(mã tầng 1 của c | lịch sử)	SID-GPT ≈3,6 triệu tham số
H8	vector đóng băng	giữ riêng từng vector trong 50 bài	LSE, top-k, MaxSim	không
H9	văn bản tiêu đề + chuyên mục	8 tiêu đề gần nhất (văn bản)	log-odds Yes/No của Qwen3-1.7B	không
H10	vector đóng băng, qua đầu MLP	attention của ứng viên lên lịch sử	$\langle \sum \alpha_i \mathbf{h}_i, \mathbf{c} \rangle$	đầu MLP + $\mathbf{W}_c$: ≈0,16–0,30 triệu
H11	vector đóng băng, qua đầu MLP	K vector sở thích (K-Means hoặc K truy vấn học được)	soft-max qua K sở thích	zero-shot: không; reader: $K\cdot$dim + đầu MLP + τ
H12	BGE-large, mở khóa 2 lớp cuối	reader trên bảng vector (làm mới định kỳ)	như H10	2 lớp BERT-large ≈25,2 triệu + reader

H1 · Lịch sử đọc dạng văn bản, mã hóa bằng LLM đóng băng

Ý tưởng	Thay vì tính trung bình vector từng bài, viết lịch sử thành một câu truy vấn rồi để LLM nhúng (embedding) cả đoạn thành một vector người dùng (kiểu EmbSum / `Instruct + Query`).
Mã hóa bài (item)	Qwen3-Embedding-0.6B, đóng băng. Văn bản `ta`, vector 1024 chiều, chuẩn hóa L2; không có prefix chỉ dẫn ở phía bài.
Mã hóa người dùng (user)	Chuỗi `"Instruct: Given the headlines a reader recently clicked, retrieve the news article they would most likely read next\nQuery: `t_1`; `t_2`; ...; `t_{10}`"`, trong đó t_i là **tiêu đề** (không có tóm tắt) của 10 bài gần nhất, tối đa 384 token. Qwen3-Emb mã hóa, lấy vector ở token cuối (last-token pooling), chuẩn hóa L2.
Điểm số	$s(u, c) = \cos(\mathbf{q}_u, \mathbf{e}_c)$. Đối chứng không có câu chỉ dẫn (`hq_plain`).
Siêu tham số	$K = 10$ tiêu đề; `q_max_len`=384; chỉ dẫn do Qwen3-Emb đề xuất. Không có tham số nào được chỉnh.
Loss / tham số học	Bản chính: **không huấn luyện** (zero-shot). Bản thêm lớp học được `histq_mlp` (v20b): hai đầu MLP residual $\mathbf{x} + \mathbf{W}_2\,\mathrm{GELU}(\mathbf{W}_1\mathrm{LN}(\mathbf{x}))$, $\mathbf{W}_2 = 0$ lúc đầu (đồng nhất), một đầu cho vector lịch sử, một đầu cho vector bài; ẩn 1024, dropout 0.1. Loss cross-entropy trên 1 click + 4 bài bỏ qua; Adam lr 10^{-3}, batch 512, tối đa 6 epoch, dừng sớm (patience 2), 2 seed; 300.000 lịch sử huấn luyện (754.956 mẫu).
Dữ liệu	Zero-shot: small 41%, large 16% tập test. `histq_mlp`: chấm toàn bộ test.

Kết quả đo (test `MINDlarge_dev`)

small -0.0211 đến -0.0014, large -0.0101 so với mean pooling. Thêm MLP: $+0.0080$ so với H1 zero-shot nhưng vẫn -0.0032 so với mean pooling.

H2 · LoRA / DoRA cho bộ mã hóa bài báo

Ý tưởng	Tinh chỉnh nhẹ encoder bằng các cặp bài người dùng cùng click, để vector bài bám sát tín hiệu hành vi, rồi mã hóa lại toàn bộ bài và dùng mean pooling.
Mã hóa bài (item)	BGE-small-en-v1.5 (BERT 12 lớp, 384 chiều) + LoRA hoặc DoRA; văn bản `ta` (tối đa 256 token); mã hóa lại toàn bộ bài sau huấn luyện.
Mã hóa người dùng (user)	Mean pooling 50 bài gần nhất của các vector đã mã hóa lại (không tham số riêng cho người dùng).
Điểm số	$s(u, c) = \cos(\bar{\mathbf{e}}_u, \mathbf{e}_c)$.
Vị trí LoRA	`query` và `value` của self-attention, **cả 12 lớp (0–11)**; $r = 16$, $\alpha = 2r = 32$, dropout 0.05, không học bias. Mỗi lớp $2 \times 16 \times (384 + 384) = 24.576$ tham số.
Tham số được học	LoRA: $24.576 \times 12 = \mathbf{294.912}$; DoRA thêm vector độ lớn 384 cho mỗi module: **304.128**. Phần còn lại của encoder đóng băng. (Biến thể đầu head tuyến tính hoặc MLP đặt sau encoder đóng băng: 3 epoch, batch 1024, lr 10^{-3}, 200.000 cặp.)
Loss	InfoNCE nhiệt độ $\tau = 0.05$ giữa hai bài đồng click, kèm Matryoshka (tính loss trên nhiều độ dài cắt của vector) và hard negative lấy từ cùng impression. Các biến thể: `lora+mrl+hn`, `dora+mrl+hn`, `lora+hn`.
Tối ưu / dữ liệu	AdamW lr $2 \cdot 10^{-4}$, không weight decay; 1 epoch, batch 32, tối đa 1.500 bước, 100.000 cặp đồng click; gradient checkpointing. Chỉ chạy trên MIND-small.

Kết quả đo (test `MINDlarge_dev`)

+0.0016 đến +0.0029 so với mean pooling; Cold AUC giảm. Gắn thêm MLP làm giảm −0.005.

H3 · Làm giàu vector bài bằng truy hồi (kNN-RAG, entity-RAG)

Ý tưởng	Bổ sung ngữ cảnh cho bài, nhất là bài mới, bằng cách lấy thông tin từ các bài cũ giống nó (truy hồi), rồi cộng vào vector bài.
Mã hóa bài (kNN)	$\mathbf{e}'_c = \mathrm{Norm}(\mathbf{e}_c + \beta\,\mathrm{Norm}(\sum_{j\in\mathcal{N}_k(c)} w_{cj}\mathbf{e}_j))$, $w_{cj} = \max(s_{cj}, 0)$ chuẩn hóa tổng bằng 1, $\mathcal{N}_k = k$ bài gần nhất **xuất hiện trước thời điểm đánh giá** (validation chỉ dùng train; test dùng train + validation).
Mã hóa bài (entity)	Mỗi thực thể Wikidata có vector ngữ cảnh = trung bình vector các bài cũ nhắc tới nó; vector bài cộng $\beta \cdot \mathrm{Norm}(\sum_e \mathrm{idf}_e\,\mathrm{ctx}_e)$ trên các thực thể e của bài.
Mã hóa người dùng	Zero-shot: mean pooling 50 bài trên vector đã làm giàu. Hoặc reader H10 huấn luyện trên bảng vector đã làm giàu (`um_knn_rag`).
Siêu tham số	$k \in \{5, 20\}$, $\beta \in \{0.25, 0.5, 1\}$, chọn trên validation. Truy hồi bằng tích vô hướng trên GPU, xử lý theo khối để vừa bộ nhớ.
Loss / tham số học	Zero-shot: **không có**. Reader: như H10 (cross-entropy 1 click + 4 bỏ qua; đầu MLP + $\mathbf{W}_c$).
Dữ liệu	Bộ nhớ truy hồi chỉ gồm bài cũ; không dùng nhãn click.

Kết quả đo (test `MINDlarge_dev`)

Cộng trực tiếp (mean pooling): kNN -0.0017, entity -0.0105. Đưa qua reader: $+0.0037$ (BGE-large), $+0.0045$ (Qwen3), chủ yếu tăng Cold AUC.

H4 · GraphRAG-lite: cộng đồng trên đồ thị bài báo

Ý tưởng	Chia bài báo thành các cụm chủ đề theo đồ thị tương đồng, rồi cộng thêm vào điểm một số hạng đo mức người dùng quan tâm đến cụm của ứng viên.
Dựng đồ thị	Mỗi bài là một nút, nối 10 bài gần nhất theo cosine của vector đóng băng; trọng số cạnh = độ tương đồng; chỉ gồm bài cũ (không rò rỉ).
Cộng đồng	Louvain (networkx, resolution 1.0). Khi đồ thị quá lớn ($>$ 80.000 nút, MIND-large), **chuyển sang MiniBatchKMeans, 500 cụm**. Tâm cụm $\mathbf{C}_k$ = trung bình vector các bài trong cụm, chuẩn hóa; bài mới gán vào tâm gần nhất.
Mã hóa người dùng	Mean pooling $\mathbf{u}$ cộng histogram cộng đồng $P_u(k)$ = tỷ lệ bài trong lịch sử thuộc cụm k.
Điểm số	$s(u,c) = \cos(\mathbf{u}, \mathbf{e}_c) + \lambda \sum_k P_u(k)\, \langle \mathbf{C}_k, \mathbf{C}_{k(c)} \rangle$.
Siêu tham số	$\lambda \in \{0.25, 0.5, 1, 2\}$ chọn trên validation. Biến thể `user_rag`: cộng thêm click của người dùng tương tự, $\gamma \in \{0.25, 0.5, 1\}$ (không chạy trên MIND-large vì không đủ bộ nhớ).
Loss / tham số học	**Không có**: toàn bộ zero-shot, chỉ dùng nội dung.

Kết quả đo (test `MINDlarge_dev`)

MIND-large (v14): validation $+0.0199$, test -0.0066; BGE-large -0.0079; MIND-small $+0.0043$ nhưng Cold AUC -0.0031. Bài mới bị gán vào tâm cụm nên mất chi tiết riêng.

H4b · GraphRAG có LLM tóm tắt từng cộng đồng

Ý tưởng	Giữ nguyên các cụm của H4, nhưng thay tâm cụm bằng vector của câu tóm tắt do LLM viết ("global summary" của GraphRAG).
Tóm tắt cụm	Với 300 cụm lớn nhất, lấy 8 tiêu đề gần tâm nhất, đưa cho Qwen3-1.7B với `COMM_PROMPT`: *"Below are headlines from one cluster of related news articles ... In one sentence (at most 40 words), describe the common topic of this cluster and what kind of reader would follow it."*, giải mã tham lam, tối đa 64 token. Cụm nhỏ giữ tâm cũ.
Mã hóa bài	Hai cách dùng vector tóm tắt $\mathbf{s}_k$ (mã hóa bằng chính encoder của lần chạy): (a) `community_llm`: thay $\mathbf{C}_k$ trong công thức của H4; (b) `community_llm_ctx`: $\mathbf{e}'_c = \mathrm{Norm}(\mathbf{e}_c + \beta\,\mathbf{s}_{k(c)})$.
Mã hóa người dùng / điểm	Như H4: mean pooling + λ·độ gần cộng đồng; hoặc mean pooling trên vector đã cộng tóm tắt.
Siêu tham số	$\lambda \in \{0.25, 0.5, 1, 2\}$, $\beta \in \{0.25, 0.5, 1\}$ chọn trên validation; 300 cụm; 8 tiêu đề mỗi cụm.
Loss / tham số học	**Không có**: LLM chỉ sinh văn bản, không huấn luyện.

Kết quả đo (test `MINDlarge_dev`)

Không khác biệt có ý nghĩa thống kê so với H4 và mean pooling (MIND-small): câu tóm tắt chỉ diễn đạt lại chủ đề mà tâm cụm đã chứa.

H5 · User Tower: LLM + LoRA đọc lịch sử dạng văn bản

Ý tưởng	Cùng đầu vào văn bản như H1 nhưng tinh chỉnh LLM để học cách đọc lịch sử, sao cho vector người dùng gần vector của bài được click kế tiếp.
Mã hóa bài (item)	Qwen3-Embedding-0.6B **đóng băng** (tháp tài liệu), vector 1024 chiều, chuẩn hóa L2.
Mã hóa người dùng (user)	Văn bản `Instruct + Query:` 10 tiêu đề gần nhất (như H1), tối đa 384 token, đi qua Qwen3-Emb có LoRA, lấy vector ở token cuối. Ba kiểu mặt nạ attention: `causal` (bản chính), `bidir` (hai chiều, kiểu LLM2Vec), `soft` (tương lai nhân $\log\lambda$, λ tăng $0 \to 1$ trong nửa đầu huấn luyện).
Điểm số	$s(u, c) = \cos(\mathbf{z}_u, \mathbf{e}_c)$.
Vị trí LoRA	**7 ma trận** `q,k,v,o,gate,up,down` trên **cả 28 lớp**; $r = 16$, $\alpha = 32$, dropout 0.05. Mỗi lớp 360.448 tham số.
Tham số được học	LoRA: $360.448 \times 28 = \mathbf{10.092.544}$ (≈1,7% của 0,6B). Embedding, LayerNorm, lm-head đóng băng.
Loss	InfoNCE nhiệt độ $\tau = 0.05$ với **negative dùng chung**: mỗi truy vấn so với *tất cả* B bài click và $B \cdot K$ bài bỏ qua của batch ($B + BK$ ứng viên); bài trùng với bài click của dòng đó bị che (tránh false negative).
Tối ưu / dữ liệu	AdamW lr 10^{-4}, lịch cosine; batch 16; fp32 gốc + autocast fp16; gradient checkpointing. v14: 800 bước (12.800 mẫu, 0.5%); v19b: 200 phút = 5.872 bước (93.952 mẫu, 3.5%).

Kết quả đo (test `MINDlarge_dev`)

0.5% dữ liệu: ngang LSE. 3.5%: hơn LSE $+0.0085$, kém reader Qwen3 -0.0048; thêm vào bộ kết hợp không cải thiện. Cùng mô hình không huấn luyện (H1) thấp hơn -0.0319.

H6 · LLM viết thêm tri thức cho bài (KAR) và hồ sơ độc giả

Ý tưởng	Cho LLM viết một đoạn ngắn mô tả chủ đề và kiểu độc giả của mỗi bài, rồi mã hóa đoạn đó và trộn vào vector bài.
LLM sinh	Qwen3-1.7B, giải mã tham lam (`do_sample=False`), tối đa 56 token mới, batch 48. Prompt: *"News headline: {title} / Summary: {abstract[:300]} // In one or two sentences (at most 50 words), state the main topic of this article and what kind of reader would be interested in it."*
Mã hóa bài (item)	$\mathbf{e}_{\text{exp}} = \text{enc}(\text{title} \,\|\, \text{đoạn LLM viết})$ bằng chính encoder của lần chạy; $\mathbf{e}'_c = \text{Norm}(\mathbf{e}_c + \alpha\, \mathbf{e}_{\text{exp}})$, $\alpha \in \{0.25, 0.5, 1\}$, chọn $\alpha = 1$. v20a: đủ 104.151 bài, 96 phút trên 2 GPU.
Mã hóa người dùng (user)	Trên vector đã trộn: mean pooling (`kar_item`), LSE (`kar_item_lse`) hoặc reader H10 (`catkarplus`, `qwen3kar`). Biến thể hồ sơ: LLM đọc 5 tiêu đề gần nhất, viết ≤ 60 từ mô tả sở thích, mã hóa thành vector truy vấn, trộn với trọng số $w \in \{0.5, 1, 2\}$.
Điểm số	cosine trên mean pooling / LSE / reader như ở các trang tương ứng.
Loss / tham số học	Phần sinh và trộn: **không huấn luyện**. Chỉ reader (H10) được huấn luyện: cross-entropy 1+4, 6 epoch, toàn bộ 2.71 triệu mẫu.
Quy mô đã đo	Mở rộng bài: toàn bộ 104.151 bài (v20a), ghép vào hệ thống ở v20c. Hồ sơ độc giả: 2.500 impression.

Kết quả đo (test `MINDlarge_dev`)

Hồ sơ: -0.0308 / -0.0278 (small / large). Mở rộng bài: $+0.0013$ so với LSE (zero-shot), reader mạnh nhất không đổi (0.4310 so với 0.4316), Cold AUC giảm; trong hệ thống (v20c): online $+0.0018$, offline $+0.0004$.

H7 · Semantic ID và bộ xếp hạng sinh SID-GPT

Ý tưởng	Mã hóa mỗi bài thành bộ 3 mã rời rạc, coi lịch sử đọc là "câu" gồm các mã, huấn luyện mô hình ngôn ngữ nhỏ dự đoán mã bài kế tiếp (kiểu TIGER).
Mã hóa bài (item)	Vector Qwen3-Emb của văn bản `cta`, RQ-KMeans 3 tầng × 256 cụm (25 vòng Lloyd mỗi tầng): tầng l lượng tử hóa phần dư của các tầng trước. Tâm cụm chỉ học trên bài của train + validation; bài test gán vào tâm gần nhất. Tầng 1: 256 cụm; tầng 2: 23.416 tiền tố; tầng 3: 79.962.
Mã hóa người dùng (user)	Chuỗi token `[PAD...] [BOS] a1 b1 c1 ... a30 b30 c30`: 30 bài gần nhất, mỗi bài 3 token (token tầng $l = 256l +$ mã), đệm trái; vị trí chỉ đếm token thật.
Điểm số	$s_l = \log P(\text{mã}_l(c) \mid \text{lịch sử}, \text{mã}_{<l}(c))$, softmax chỉ trong 256 mã cùng tầng; điểm = tổng s_l trên tập tầng chọn ở validation ($\{1\}, \{1,2\}, \{1,2,3\}$, có/không trừ PMI). Được chọn: **chỉ tầng 1, không PMI**. Biến thể `sid_profile`: tỷ lệ lịch sử cùng tiền tố mã với ứng viên (zero-shot).
Kiến trúc SID-GPT	Transformer nhân quả $d = 256$, 4 lớp, 4 head, dropout 0.1, MLP $4d$; embedding token + vị trí + tầng mã; đầu ra 768 lớp. ≈3,6 triệu tham số, **học từ đầu**.
Loss / tối ưu	Dự đoán token kế tiếp, trọng số token của lịch sử 0.5, của bài click 1.0. AdamW lr 10^{-3}, weight decay 0.01, khởi động 100 bước rồi cosine, cắt gradient 1.0, batch 256, 4 epoch (18.392 bước), chọn epoch theo nDCG@10 trên 3.000 impression validation.
Dữ liệu	Các mẫu `train_core` (lịch sử, bài click); mẫu âm không dùng.

Kết quả đo (test `MINDlarge_dev`)

small: 0.2898 ≈ ngẫu nhiên. large (v20b): cộng cả 3 tầng 0.2990; chỉ tầng 1 **0.3473** (+0.0483); đổi lịch sử sang người khác giảm −0.0626; vẫn −0.0314 so với mean pooling (0.3787), Cold AUC −0.10.

H8 · Tương tác muộn (LSE, top-k): không có tham số học

Ý tưởng	Không gộp lịch sử thành một vector; so ứng viên với *từng* bài đã đọc rồi tổng hợp bằng một phép "soft-max" (ColBERT-style).
Mã hóa bài (item)	Vector đóng băng (BGE-small / BGE-large / Qwen3-Emb / concat), chuẩn hóa L2.
Mã hóa người dùng (user)	Không có vector người dùng: giữ nguyên tập 50 vector bài đã đọc (biến thể 100 / 200 bài ở bước F). Người dùng không lịch sử: điểm 0.
Điểm số **LSE:** $s = \tau\big(\log \sum_i e^{\mathrm{sim}_i/\tau} - \log n\big)$; **top-$k$:** trung bình k giá trị sim_i lớn nhất; **MaxSim:** $\max_i \mathrm{sim}_i$; **recency:** trung bình có trọng số $e^{-\lambda \cdot \mathrm{age}}$.	Với $\mathrm{sim}_i = \langle \mathbf{v}_i, \mathbf{v}_c \rangle$ và $n = \lvert\mathcal{H}_u\rvert$:
Siêu tham số	$\tau \in \{0.02, 0.03, 0.05, 0.07, 0.1, 0.15, 0.2, 0.3, 0.5\}$; $k \in \{2, 3, 4, 5, 7, 10\}$; $\lambda \in \{0.02, 0.05, 0.1, 0.2\}$; chọn trên validation. $\tau \to \infty$ cho mean pooling, $\tau \to 0$ cho MaxSim.
Loss	**Không có**.
Tham số được học	**Không có**: chỉ chọn τ hoặc k trên validation.

Kết quả đo (test `MINDlarge_dev`)

LSE $+0.0113$, top-k $+0.0111$ (BGE-large, large); $+0.0130$ / $+0.0143$ trên Qwen3. MaxSim -0.0017; recency -0.0000. K-Means $K = 5$: $+0.0090$.

H9 · LLM chấm điểm ứng viên (xếp hạng lại top-10)

Ý tưởng	Dùng một LLM nhỏ đọc lịch sử và từng ứng viên rồi trả lời Có/Không ("reranker" kiểu LLMRank), chỉ để xếp lại nhóm đầu.
Vòng 1	Xếp hạng bằng mean pooling trên vector đóng băng (BGE / Qwen3 theo lần chạy); lấy top-$k = 10$ của mỗi impression. Các ứng viên còn lại giữ nguyên và luôn đứng dưới nhóm này.
Mã hóa bài / người dùng	Dều ở dạng **văn bản**: người dùng = 8 tiêu đề gần nhất (`rerank_hist`=8, chuỗi "`* title`"); ứng viên = tiêu đề + chuyên mục. Không có vector.
Prompt	*"A news reader recently read these articles (oldest first): {hist} / Candidate article: "{title}"(category: {cat}) / Would this reader be interested in clicking the candidate article? Answer with exactly one word: Yes or No."*
Điểm số	Qwen3-1.7B (zero-shot, fp16): log-odds $\log P(\text{Yes}) - \log P(\text{No})$ ở token trả lời. `rerank_llm`: chỉ dùng điểm LLM; `rerank_fused`: $\mathrm{z}(s_{\text{vòng 1}}) + w \cdot \mathrm{z}(\text{log-odds})$, $w \in \{0.5, 1, 2\}$ chọn trên validation, z = chuẩn hóa z-score trong nhóm.
Loss / tham số học	**Không có**: hoàn toàn zero-shot.
Quy mô đã đo	Do chi phí sinh: 600 impression validation, 2.000 impression test (large 0.5%); ước tính toàn bộ test ≈38 giờ trên T4.

Kết quả đo (test `MINDlarge_dev`)

small -0.0112; large -0.0092 (không có ý nghĩa thống kê), cả hai trên $n = 2.000$. Xác suất sinh chưa được hiệu chuẩn và LLM 1,7B chưa đủ mạnh để phân biệt các bài cùng chủ đề.

H10 · Reader theo ứng viên: ứng viên làm truy vấn attention

Ý tưởng	Một tầng nhẹ có huấn luyện trên bảng vector đóng băng: để chính ứng viên quyết định bài nào trong lịch sử đáng chú ý.
Mã hóa bài (item)	$\mathbf{c} = f(\mathbf{E}_c)$ với đầu f dùng chung cho bài ứng viên và bài lịch sử: $f = \mathrm{Linear}(d \to \mathrm{dim}) \to \mathrm{GELU} \to \mathrm{LayerNorm} \to \mathrm{Dropout}(0.2) \to \mathrm{Linear}(\mathrm{dim} \to \mathrm{dim})$. `dim`=64 (V10, small) hoặc 128 (v16 trở đi); d = 384 / 1024 / 2048.
Mã hóa người dùng (user)	$\alpha_i = \mathrm{softmax}_i\big(\langle \mathbf{W}_c\mathbf{c}, \mathbf{h}_i\rangle / \sqrt{\mathrm{dim}}\big)$ với $\mathbf{h}_i = f(\mathbf{E}_i)$, i trong 50 bài gần nhất (có mặt nạ); $\mathbf{u} = \sum_i \alpha_i \mathbf{h}_i$ phụ thuộc ứng viên. $\mathbf{W}_c \in \mathbb{R}^{\mathrm{dim}\times\mathrm{dim}}$ không bias.
Điểm số	$s(u, c) = \langle \mathbf{u}, \mathbf{c}\rangle$.
Biến thể	`um_frozen` (vector gốc), `um_knn_rag` (đã làm giàu, H3), `um_text` (văn bản `cta`), `um_prior` (chỉ dựa vào bài, làm đặc trưng cho GBDT), `ff` / `nrms` / `sca` (nén lịch sử một vector / thêm self-attention).
Loss	Cross-entropy (softmax) trên 1 bài click + 4 bài bỏ qua lấy mẫu trong cùng impression: $\mathcal{L} = -\log \frac{e^{s(u,c^+)}}{e^{s(u,c^+)} + \sum_{c^-} e^{s(u,c^-)}}$.
Tối ưu	Adam lr 10^{-3}, wd 10^{-5}, batch 64; tối đa 12 epoch (v18b/v19a: 6 epoch, lr giảm dần, toàn bộ 2.71 triệu mẫu); dừng sớm theo nDCG@10 validation (patience 2); 2–3 seed.
Tham số được học	Đầu f + $\mathbf{W}_c$. Với dim 128: BGE-large (d=1024) ≈164.352; vector nối (d=2048) ≈295.424. BGE-small với dim 64: ≈33.024. Vector **E** đóng băng, không cập nhật.

Kết quả đo (test `MINDlarge_dev`)

Hơn LSE: MIND-large BGE-large +0.0105, Qwen3 +0.0134; MIND-small Qwen3 +0.0084 (BGE-small −0.0069). Vector nối: 0.4223; train đủ 2.71 triệu mẫu + kNN: 0.4316.

H11 · Biểu diễn đa sở thích: K-Means zero-shot và reader K truy vấn

Ý tưởng	Một độc giả có nhiều mối quan tâm; thay vì một vector người dùng, biểu diễn bằng K vector sở thích rồi lấy "soft-max" khi chấm ứng viên.
Mã hóa bài (item)	Vector đóng băng; với reader học được thì qua đầu MLP f như H10 (dim 64, dropout 0.2).
User, bản K-Means (zero-shot)	Spherical k-means trên 50 vector bài đã đọc, 3 vòng; khởi tạo từ bài click gần nhất rồi bài xa nhất so với các tâm đã chọn. $\boldsymbol{\mu}_k$ = trung bình các bài trong nhóm k, share_k = tỷ lệ bài của nhóm. $K \in \{2, 3, 5\}$.
Điểm (K-Means)	$s = \tau \log \sum_k \exp\big(\langle \mathbf{c}, \boldsymbol{\mu}_k \rangle / \tau + \log \text{share}_k\big)$. $K = 1$ trùng mean pooling; $K \geq n$ trùng LSE.
User, bản học được	$K = 4$ vector truy vấn $\mathbf{q}_k \sim \mathcal{N}(0, 1)$ là tham số; sở thích $\mathbf{u}_k = \sum_i \text{softmax}_i(\langle \mathbf{q}_k, \mathbf{W}_k \mathbf{h}_i \rangle / \sqrt{\dim})\, \mathbf{h}_i$ (không phụ thuộc ứng viên). Điểm: $s = \tau\big(\log \sum_k e^{\langle \mathbf{u}_k, \mathbf{c} \rangle / \tau} - \log K\big)$, $\tau = \exp(\log \tau_0)$ **học được**, chặn dưới 0.05.
Loss	Cross-entropy 1 click + 4 bỏ qua (như H10). Bản `mi4d` cộng phạt đa dạng $\lambda \cdot \overline{\cos^2(\mathbf{u}_k, \mathbf{u}_l)}$ giữa các sở thích khác nhau của cùng người dùng; `mi1` ($K = 1$) là đối chứng.
Tham số được học	K-Means: **không**. Reader: $\mathbf{q}_k$ ($K \cdot \dim = 256$), $\mathbf{W}_k$ ($\dim^2$=4.096), $\log \tau_0$ (1), cộng đầu MLP f.

Kết quả đo (test `MINDlarge_dev`)

K-Means (BGE-large) $K = 5$: $+0.0090$ so với mean pooling nhưng -0.0024 so với LSE. Reader không phạt: các sở thích sụp về một hướng (cos 0.85–0.87); có phạt: tách rõ (cos 0.34–0.39) nhưng điểm không tăng ($+0.0004$, n.s.).

H12 · Mở khóa 2 lớp cuối của bộ mã hóa dưới reader (kiểu PLM-NR)

Ý tưởng	Huấn luyện đồng thời 2 lớp transformer cuối của BGE-large và reader, như PLM-NR tinh chỉnh các lớp cuối của mô hình tiền huấn luyện, nhưng làm đủ rẻ để chạy trên một GPU T4.
Mã hóa bài (item)	BGE-large (BERT-large 24 lớp, 1024 chiều). Lớp 0–21 đóng băng: đầu ra của lớp 21 được **lưu đệm một lần** (fp16, $[\text{bài}, 96, 1024]$, ≈20,5 GB, cắt 96 token). Hai lớp 22–23 (`ft_layers`=2) được huấn luyện; chỉ phía **ứng viên** nhận gradient.
Mã hóa người dùng (user)	Reader theo ứng viên của H10 (`FTReader`), khởi tạo từ reader đã huấn luyện trên bảng đóng băng. Phía lịch sử đọc bảng vector làm mới bằng 2 lớp hiện tại mỗi 600 bước (stop-gradient).
Điểm số	$s(u, c) = \langle \mathbf{u}, \mathbf{c} \rangle$ như H10.
Loss	Cross-entropy 1 click + 4 bỏ qua (như H10); mỗi bước 32 mẫu.
Siêu tham số	lr lớp encoder $2 \cdot 10^{-5}$; lr reader $3 \cdot 10^{-4}$; 18.000 bước; `ft_refresh`=600; kiểm tra validation mỗi 1.800 bước; dừng sau 4 lần không cải thiện; tối đa 110 phút; chọn checkpoint theo validation cân lại về 80% bài mới. Cổng quyết định: cần $\geq +0.006$ nDCG@10.
Tham số được học	2 lớp BERT-large: $2 \times 12.596.224 \approx \mathbf{25,2}$ triệu (attention 4.198.400 + FFN 8.393.728 + LayerNorm 4.096 mỗi lớp; tính từ kiến trúc), cộng reader ≈0,16 triệu.
Đối chứng	Nhánh `ft_base`: cùng reader, cùng số bước, cùng thứ tự mẫu, nhưng encoder đóng băng hoàn toàn.

Kết quả đo (test `MINDlarge_dev`)

nDCG@10 0.4208 → 0.4213 (+0.0005 [−0.0001, +0.0010], n.s.); Cold AUC −0.0069; mới chạy ≈0.5 epoch, một seed. Không qua ngưỡng +0.006.

Tổng hợp: tham số được học, hàm mất mát và tối ưu

Mã	Tham số được học	Hàm mất mát	Tối ưu	Dữ liệu huấn luyện
H1	không (MLP residual: có)	(MLP) CE, 1+4	(MLP) Adam 10^{-3}, bs 512	(MLP) 300.000 lịch sử
H2	LoRA q, v × 12 lớp: 294.912 (DoRA 304.128)	InfoNCE τ=0.05 + Matryoshka + hard negative	AdamW $2 \cdot 10^{-4}$, bs 32	1.500 bước, $\leq$100.000 cặp
H3	không (reader: như H10)	–	–	–
H4, H4b	không	–	–	–
H5	LoRA 7 ma trận × 28 lớp: 10.092.544	InfoNCE τ=0.05, negative dùng chung B+BK	AdamW 10^{-4}, cosine, bs 16	12.800 mẫu (v14); 93.952 (v19b)
H6	không (reader: như H10)	–	–	đoạn LLM viết cho 104.151 bài
H7	SID-GPT ≈3,6 triệu	Dự đoán token kế tiếp, trọng số 0.5 / 1.0	AdamW 10^{-3}, wd 0.01, cosine, bs 256	4 epoch, 18.392 bước
H8	không	–	–	chỉ chọn τ, k trên validation
H9	không	–	–	chỉ chọn w trên validation
H10	đầu MLP + $\mathbf{W}_c$: 0,03–0,30 triệu	CE (softmax), 1+4	Adam 10^{-3}, wd 10^{-5}, bs 64	đến 2.71 triệu mẫu, 6–12 epoch
H11	K-Means: không; reader: $\mathbf{q}_k$, $\mathbf{W}_k$, τ, đầu MLP	CE 1+4 (+ phạt đa dạng)	như H10	như H10
H12	2 lớp BERT-large 25,2 triệu + reader	CE 1+4	AdamW (encoder $2 \cdot 10^{-5}$, reader $3 \cdot 10^{-4}$), bs 32	18.000 bước (≈0.5 epoch)

CE = cross-entropy softmax; "1+4" = 1 bài click và 4 bài bỏ qua lấy mẫu trong cùng impression. Số tham số của H2, H5, H10 tính từ kích thước lớp (khớp số tham số học được in trong log); số của H12 và H10 vector nối tính từ kiến trúc.

XIN TRÂN TRỌNG CẢM ƠN!

Câu hỏi và thảo luận