Gợi ý tin tức sử dụng các kỹ thuật LLM

Mười hai hướng LLM trên dữ liệu MIND: hướng nào hiệu quả, hướng nào không

Người thực hiện: Nguyễn Nam Hán – 20252095M
Nguyễn Phúc Nguyên – 20261222M
Lê Văn Đức – 20261233M

GVHD: TS. Ngô Văn Linh

2026

Lời thoại gợi ý

Kính chào thầy cô và các bạn. Nhóm em trình bày đề tài gợi ý tin tức sử dụng các kỹ thuật LLM. Câu hỏi xuyên suốt: trong rất nhiều hướng dùng LLM cho hệ gợi ý những năm 2024–2026, hướng nào thật sự có ích cho tin tức khi được đánh giá chặt chẽ; và từ các hướng có ích đó, có thể xây một hệ thống chạy được trên một GPU phổ thông hay không.

Nội dung trình bày

1. Bài toán, dữ liệu và câu hỏi nghiên cứu
2. Cách tiếp cận: quy trình 4 bước, 12 họ giả thuyết, giao thức đánh giá
3. Bức tranh tổng thể: hướng nào thành công, hướng nào không
4. Chẩn đoán điểm nghẽn: bộ mã hóa hay tầng tổng hợp lịch sử
5. Các hướng thành công và vì sao
6. Các hướng không thành công và vì sao
7. Từ thành phần đến hệ thống: hợp nhất, GBDT, rò rỉ thời gian
8. Kết quả, so sánh với công bố, giới hạn và kết luận

Phụ lục: thuật ngữ · câu hỏi có thể gặp · các lần chạy và nguồn số liệu · tài liệu tham khảo

Lời thoại gợi ý

Bài trình bày đi theo đúng trình tự nghiên cứu: đặt bài toán, thử các hướng, xem hướng nào đứng vững, chẩn đoán vì sao, rồi ghép các hướng đứng vững thành hệ thống cuối. Phần 3 là phần quan trọng nhất: một bảng cho biết mỗi hướng H1–H12 thành công hay thất bại.

Tóm tắt trong một trang

Bài toán

Dự đoán độc giả sẽ click bài nào trong danh sách ứng viên, dựa trên lịch sử đọc (bộ dữ liệu MIND của Microsoft). Khó nhất: **82.25%** click ở tập test rơi vào **bài mới** chưa từng xuất hiện khi huấn luyện, nên phải hiểu nội dung bài thay vì nhớ ID.

Cách làm

Mã hóa văn bản bài báo bằng LLM / encoder **giữ cố định trọng số**. Thử **12 họ kỹ thuật LLM 2024–2026** (H1–H12) và nhóm dữ liệu đầu vào (F): sàng lọc trên MIND-small, xác nhận trên MIND-large. Mọi so sánh đều ghép cặp, có khoảng tin cậy, chia dữ liệu theo thời gian.

Kết quả

2 hướng thành công rõ (H8, H10), **2** hướng có điều kiện (F, H3), **10** hướng không hơn đối chứng mạnh. Hệ thống 3 tầng (embedding cố định → reader → GBDT): nDCG@10 **0.3787** → **0.4516** ở chế độ offline; **0.4731** khi dùng thêm click trong ngày (online).

Bài học

(1) Điểm nghẽn là **tầng tổng hợp lịch sử đọc**, không phải kích thước bộ mã hóa. (2) Các kỹ thuật **nén hoặc viết lại** biểu diễn bằng LLM làm mất chi tiết của bài mới. (3) Phải đánh giá trung thực: validation có trọng số theo tỷ lệ bài mới, cross-validation theo khối thời gian.

Lời thoại gợi ý

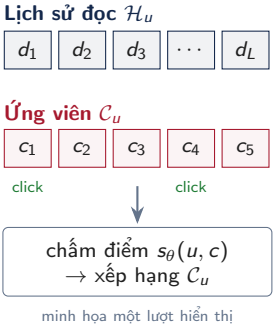
Nếu chỉ nhớ một slide thì là slide này. Bài toán khó vì hơn 82% click rơi vào bài mới. Nhóm giữ bộ mã hóa cố định và thử 12 họ kỹ thuật LLM; chỉ hai họ thành công rõ ràng, hai họ có điều kiện, mười họ không hơn đối chứng mạnh. Ghép các hướng đứng vững cho nDCG@10 tăng từ 0.3787 lên 0.4516.

Bài toán khuyến nghị tin tức

Mỗi **lượt hiển thị** (impression) gồm lịch sử đọc $\mathcal{H}_u = [d_1, \ldots, d_L]$ của độc giả u và danh sách ứng viên $\mathcal{C}_u$. Mô hình chấm điểm $s_\theta(u, c)$ cho từng ứng viên để xếp hạng; nhãn là bài nào được click. Ba đặc điểm làm bài toán khó:

- **Bài mới chiếm đa số (cold-start):** phần lớn click rơi vào bài chưa có trong dữ liệu huấn luyện, nên lọc cộng tác theo ID hoạt động kém.
- **Giá trị tin giảm nhanh theo thời gian:** phân phối dữ liệu dịch chuyển giữa quá khứ (huấn luyện) và tương lai (test).
- **Ràng buộc độ trễ khi phục vụ:** không thể chạy LLM nhiều tỷ tham số cho từng lượt hiển thị.

Ý chính. cần biểu diễn *nội dung* bài báo đủ tốt để xếp hạng cả bài chưa từng thấy, với chi phí phục vụ thấp.



minh họa một lượt hiển thị

Lời thoại gợi ý

Một lượt hiển thị gồm lịch sử đọc của người dùng và danh sách bài được hiển thị; nhiệm vụ là xếp các bài được click lên đầu. Khó vì đa số bài là bài mới, sở thích trôi theo thời gian, và phải phục vụ nhanh. Vì vậy hướng đi của nhóm là dùng LLM để hiểu nội dung bài, nhưng giữ chi phí lúc phục vụ thấp.

Dữ liệu MIND và cách chấm điểm

	MIND-small	MIND-large
Bài báo	65.238	104.151
Người dùng	–	1.000.000
Impression huấn luyện	–	2.232.748
Impression test	73.152	376.471
Cặp ứng viên test	–	14.085.557
Click test vào bài mới	85.9%	82.25%
Dùng để	sàng lọc	xác nhận

Test = tập *_dev (nhãn của test chính thức không công khai), chỉ chạm một lần ở cuối. Validation là ngày cuối của tập huấn luyện.

Cách đọc các chỉ số

- **AUC**: xác suất một bài được click xếp trên một bài không được click trong cùng lượt hiển thị (0.5 là ngẫu nhiên).
- **MRR**: trung bình của 1 / thứ hạng các bài được click.
- **nDCG@10** (chỉ số chính): chất lượng 10 vị trí đầu; bài được click càng lên cao, điểm càng lớn.
- **Cold AUC / Warm AUC**: AUC chỉ tính trên các bài được click *chưa từng* / *đã từng* xuất hiện khi huấn luyện.

Lời thoại gợi ý

MIND-small dùng để sàng lọc nhanh nhiều hướng; MIND-large dùng để xác nhận và xây hệ cuối. Chỉ số chính là nDCG@10. Cold AUC rất quan trọng vì hơn 80% click là bài mới: một kỹ thuật làm tăng nDCG nhưng giảm Cold AUC thường chỉ đang học thuộc bài cũ.

Năm câu hỏi nghiên cứu

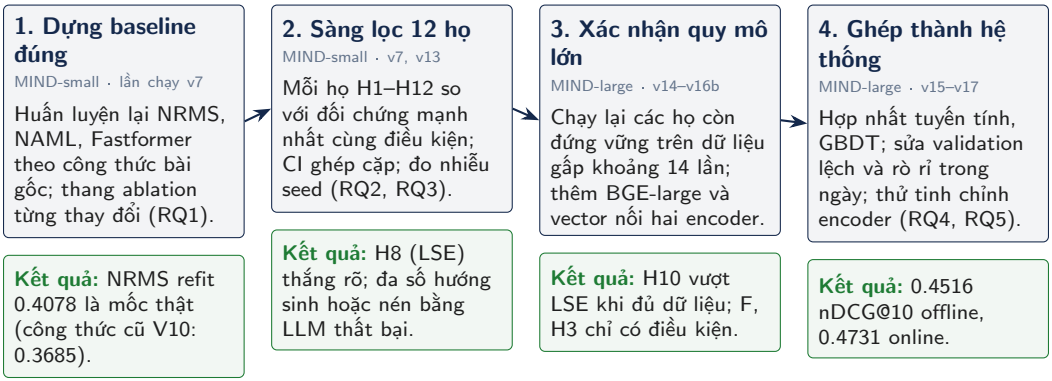
	Câu hỏi	Trả lời ở
RQ1	Embedding LLM giữ cố định đứng ở đâu so với NRMS, NAML, Fastformer được huấn luyện lại đúng cách?	Phần 4
RQ2	Điểm nghẽn nằm ở bộ mã hóa, ở dữ liệu đầu vào, hay ở tầng tổng hợp lịch sử đọc?	Phần 4, 5
RQ3	Các hướng LLM 2024–2026 (H1–H12) có còn hiệu quả khi đánh giá chặt trên tin tức?	Phần 3, 5, 6
RQ4	Ở quy mô MIND-large: hợp nhất tuyến tính hay GBDT, và làm sao để điểm validation đáng tin?	Phần 7
RQ5	Tinh chỉnh bộ mã hóa có thu hẹp khoảng cách với các PLM tinh chỉnh end-to-end không?	Phần 6, 8

Ý chính. mỗi phần sau trả lời một hoặc vài câu hỏi; slide kết luận trả lời lại cả năm câu một cách ngắn gọn.

Lời thoại gợi ý

Năm câu hỏi này là khung của cả bài. Câu hỏi quan trọng nhất là RQ3: các hướng LLM mới có đứng vững không. RQ1 và RQ2 giải thích vì sao; RQ4 và RQ5 nói về việc xây hệ thống và giới hạn còn lại.

Quy trình nghiên cứu: bốn bước, mỗi bước giữ lại những gì đứng vững



Ý chính. nghiên cứu đi theo kiểu phễu: thử rộng trên dữ liệu nhỏ, chỉ mang các hướng đứng vững lên dữ liệu lớn, rồi ghép chúng thành hệ thống. Bảng các lần chạy ở phụ lục.

Lời thoại gợi ý

Slide này trả lời câu hỏi "nhóm đã nghiên cứu như thế nào". Bước 1: dựng baseline đúng, vì so với baseline yếu thì kỹ thuật nào cũng trông tốt. Bước 2: sàng lọc 12 họ trên MIND-small, mỗi họ so với đối chứng mạnh nhất. Bước 3: mang các họ còn đứng vững lên MIND-large để xác nhận. Bước 4: ghép các họ đứng vững thành hệ thống và sửa hai lỗi đánh giá là validation lệch và rò rỉ trong ngày.

Các hướng LLM 2024–2026 và giả thuyết tương ứng

Hướng trong văn liệu	Công trình đại diện	Giả thuyết
LLM làm bộ mã hóa	LLM2Vec (COLM'24), LLMEmb (AAAI'25), LLM2Rec (KDD'25)	RQ2, H2, H12
Biểu diễn độc giả	EmbSum (RecSys'24)	H1, H5
Tri thức do LLM sinh	KAR (RecSys'24), ONCE (WSDM'24), Yada & Yamana	H6, F
RAG, GraphRAG	GraphRAG (Edge và cs. '24), KG-RAG (ACL'25)	H3, H4, H4b
Semantic ID	TIGER (NeurIPS'23), LETTER (CIKM'24), RPG (KDD'25)	H7, SID-News
LLM xếp hạng	LLMRank (ECIR'24), LLM4Rerank (WWW'25)	H9
Tương tác muộn	ColBERT (SIGIR'20)	H8
Mô hình theo ứng viên	CAUM (SIGIR'22)	H10
Đa sở thích	ComiRec (KDD'20), MINER (Findings ACL'22)	H11
Tinh chỉnh PLM	PLM-NR (SIGIR'21), UNBERT (IJCAI'21)	H12
Ngữ nghĩa + cộng tác	PAD (SIGIR'25)	T

Ý chính. mỗi mã H là một câu hỏi "hướng này có giúp tin tức không?" và được so với đối chứng mạnh nhất cùng điều kiện. SID-News và T là hai hướng đã thiết kế nhưng chưa đo.

Lời thoại gợi ý

Slide này cho biết mỗi giả thuyết đến từ đâu. Nhóm không tự nghĩ ra các hướng: mỗi H tương ứng một dòng công trình 2024–2026 ở các hội nghị lớn. Cột cuối là mã giả thuyết; phần 3 sẽ cho kết luận của từng mã.

Mô hình cơ sở và các bộ mã hóa được khảo sát

Baseline học từ log click

- **NRMS** (EMNLP 2019): self-attention nhiều đầu cho bài báo và người dùng.
- **NAML** (IJCAI 2019): CNN đa góc nhìn trên tiêu đề, tóm tắt, chuyên mục.
- **Fastformer** (2021): additive attention, độ phức tạp tuyến tính.
- Cả ba được **huấn luyện lại** với vector từ GloVe-300 như bài gốc; **NRMS refit** học thêm các ngày validation.
- **PLM-NR**, **UNBERT** (2021): tinh chỉnh PLM end-to-end; chỉ dùng số đã công bố.

Bộ mã hóa văn bản giữ cố định

- **BGE-small / base / large** (384 / 768 / 1024 chiều): encoder hai chiều kiểu BERT, lấy vector CLS.
- **Qwen3-Embedding-0.6B** (1024 chiều): xây trên LLM decoder, lấy vector token cuối.
- **TF-IDF + LSA** (256 chiều): đối chứng chỉ dùng từ vựng.
- **Qwen3-1.7B**: LLM sinh văn bản, chỉ dùng cho H6 (viết hồ sơ) và H9 (chấm điểm).

Ý chính. mọi kỹ thuật LLM được so với baseline huấn luyện lại đúng cách, không phải với số cũ yếu (NRMS theo công thức cũ V10 chỉ đạt 0.3685 nDCG@10).

Lời thoại gợi ý

Điểm khác biệt về phương pháp: nhóm huấn luyện lại NRMS, NAML, Fastformer theo đúng công thức bài báo, nên các so sánh với LLM là công bằng. Bộ mã hóa văn bản luôn giữ cố định; ta chỉ học các tầng nhẹ phía trên.

Giao thức đánh giá và cách đọc một kết quả

- **Chia theo thời gian:** validation là ngày cuối của tập huấn luyện; test (*_dev) chỉ chạm một lần ở cuối. Mọi lựa chọn (tham số, epoch, trọng số ghép, cấu hình stacker) chỉ dùng validation.
- **So sánh ghép cặp theo từng impression:** báo Δ và khoảng tin cậy (CI) 95% xấp xỉ chuẩn, $\pm 1.96 \cdot \mathrm{SE}$; Cold/Warm AUC dùng SE theo cụm impression.
- **Chọn đại diện của m họ trên validation**, kết luận có hiệu chỉnh Bonferroni: $z_{\mathrm{adj}} = \Phi^{-1}\left(1 - \frac{0.05}{2m}\right)$.
- Báo cáo riêng **Cold AUC / Warm AUC**; mô hình có huấn luyện chạy 2–3 seed.
- **73 kiểm thử tự động** trước mỗi lần chạy (đúng chỉ số, rò rỉ nhãn, bộ nhớ); dự đoán kết quả được ghi lại trước khi chạy.

Cách đọc "Δ [CI 95%]"

BGE-large so với Qwen3 (cùng reader):
$+0.0102\ [+0.0095, +0.0108] \Rightarrow$ CI không chứa 0: **khác biệt có ý nghĩa**.

kNN trong reader, trên vector nối:
$+0.0003\ [-0.0001, +0.0007] \Rightarrow$ CI chứa 0: **coi như không khác**.

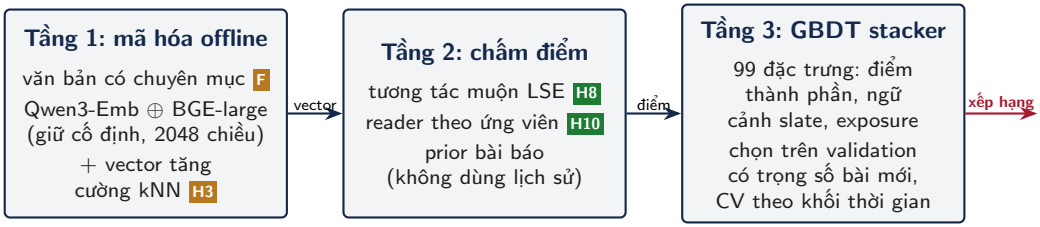
Lưu ý: nhiễu seed

CI chỉ tính nhiễu của mẫu test. Hai seed của cùng một mô hình lệch **0.007–0.014** nDCG@10 trên MIND-small, nên chênh nhỏ hơn mức này giữa hai mô hình đã huấn luyện chưa phải kết luận.

Lời thoại gợi ý

Giao thức này là lý do nhiều hướng "trông tốt" trong văn liệu lại không đứng vững ở đây. Cách đọc đơn giản: nếu khoảng tin cậy không chứa 0 thì khác biệt có ý nghĩa thống kê. Nhưng khoảng tin cậy không tính nhiễu do seed huấn luyện, nên với mô hình đã huấn luyện cần thêm biên an toàn.

Hệ thống cuối cùng: ba tầng, gắn với các giả thuyết



Ý chính. ba tầng được ghép từ các hướng đứng vững: H8 H10 thành công và F H3 có điều kiện. Mọi hướng khác bị loại sau khi đánh giá.

Lời thoại gợi ý

Đây là hệ thống cuối, để thầy cô thấy trước đích đến. Tầng 1 mã hóa mỗi bài một lần bằng hai encoder giữ cố định. Tầng 2 tạo nhiều góc nhìn về độ phù hợp giữa người dùng và bài, trong đó quan trọng nhất là LSE và reader theo ứng viên. Tầng 3 là GBDT ghép các điểm này với đặc trưng ngữ cảnh và exposure. Các nhãn màu cho biết mỗi thành phần đến từ giả thuyết nào.

Bức tranh tổng thể: hướng nào thành công, hướng nào không

Thành công (2)

H8 · LSE, top-k
+0.011 đến +0.014 so với mean pooling; không thêm tham số; lặp lại trên 2 encoder, 2 quy mô

H10 · Reader theo ứng viên
+0.0105 so với LSE (MIND-large); thành phần mạnh nhất. MIND-small: chỉ hơn LSE với Qwen3

Có điều kiện (2)

F · Chuyên mục trong văn bản
+0.0186 với Qwen3; không giúp BGE, không giúp bài mới

H3 · Truy hồi kNN
+0.0037 khi đưa qua reader, chủ yếu tăng Cold AUC; dùng thẳng thì giảm

Không hiệu quả (10)

H1 lịch sử dạng văn bản: −0.0211
H2 LoRA/DoRA cho encoder: chỉ +0.003
H4 GraphRAG: val dương, test −0.0066
H4b LLM tóm tắt cụm: không khác
H5 tháp người dùng LoRA: bằng LSE
H6 hồ sơ do LLM viết: −0.0308
H7 Semantic ID: ngang ngẫu nhiên
H9 LLM chấm điểm: −0.0112
H11 đa sở thích: thấp hơn LSE
H12 mở khóa encoder: +0.0005 (n.s.)

Chưa đo: T (cổng cold/warm) và SID-News: đã có mã, chưa có lần chạy đo kết quả.

Ý chính. "thành công" = hơn *đối chứng mạnh nhất* cùng điều kiện (không chỉ hơn mean pooling), CI không chứa 0 và được giữ trong hệ thống cuối.

Lời thoại gợi ý

Đây là câu trả lời trực tiếp cho câu hỏi "hướng nào thành công". Thành công rõ chỉ có H8 và H10: cả hai đều thuộc tầng tổng hợp lịch sử. F và H3 có ích trong điều kiện cụ thể. Mười hướng còn lại không hơn đối chứng mạnh; nhiều hướng trong số đó vẫn hơn mean pooling, nhưng mean pooling là đối chứng yếu, nên không tính là thành công. Họ T và SID-News chưa có số đo nên không xếp loại.

Tra cứu nhanh: kết luận cho từng hướng H1–H12

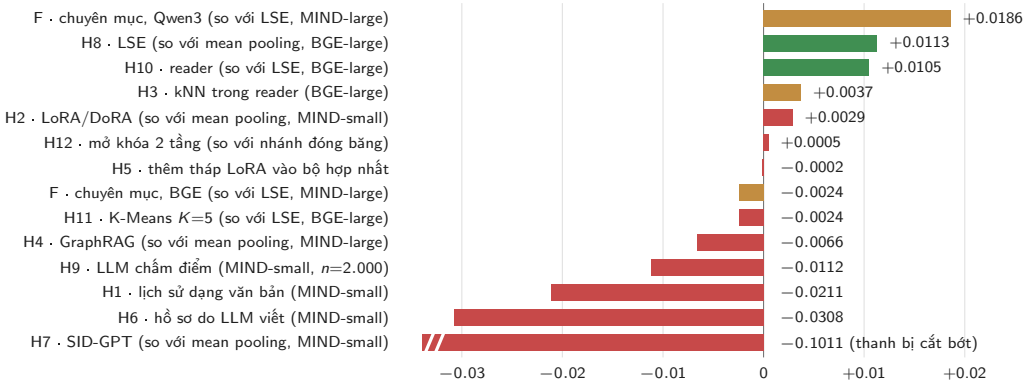
Mã	Hướng đã thử	Kết quả chính (so với đối chứng mạnh nhất)	Kết luận
H1	Lịch sử đọc thành văn bản	-0.0211 đến -0.0014 so với mean pooling	KHÔNG HIỆU QUẢ
H2	LoRA/DoRA cho encoder	$+0.0016$ đến $+0.0029$; Cold AUC giảm	KHÔNG HIỆU QUẢ
H3	kNN bổ sung vector bài	qua reader $+0.0037$; dùng thẳng thì giảm	CÓ ĐIỀU KIỆN
H4	GraphRAG (tâm cụm)	val $+0.0199$ nhưng test -0.0066	KHÔNG HIỆU QUẢ
H4b	LLM tóm tắt mỗi cụm	không khác biệt thống kê	KHÔNG HIỆU QUẢ
H5	Tháp người dùng (LoRA)	bằng LSE (-0.0000); không giúp bộ hợp nhất	KHÔNG HIỆU QUẢ
H6	LLM sinh hồ sơ, mô tả bài	hồ sơ -0.0308; mô tả bài: mất khi có popularity	KHÔNG HIỆU QUẢ
H7	Semantic ID + SID-GPT	0.2898, ngang vector ngẫu nhiên (0.2897)	KHÔNG HIỆU QUẢ
H8	**Tương tác muộn (LSE)**	**$+0.011$ đến $+0.014$, ở 2 encoder và 2 quy mô**	THÀNH CÔNG
H9	LLM chấm điểm ứng viên	-0.0112 $[-0.0216, -0.0008]$, $n = 2.000$	KHÔNG HIỆU QUẢ
H10	**Reader theo ứng viên**	**hơn LSE $+0.008$ đến $+0.013$ (trừ BGE-small)**	THÀNH CÔNG
H11	Đa sở thích	K-Means -0.0024 so với LSE; reader $K = 4$ n.s.	KHÔNG HIỆU QUẢ
H12	Mở khóa 2 tầng BGE-large	$+0.0005$ (n.s.); Cold AUC -0.0069	KHÔNG HIỆU QUẢ
F	Chuyên mục trong văn bản	Qwen3 $+0.0186$, BGE -0.0024 so với LSE	CÓ ĐIỀU KIỆN

CHƯA ĐO T (cổng cold/warm kiểu PAD) và SID-News (Semantic ID cải tiến): đã có mã, chưa có lần chạy đo. Đo trên MIND-small: H1, H2, H6, H7, H9; trên MIND-large: H4, H12, F; cả hai: H3, H5, H8, H10, H11. n.s. = không có ý nghĩa thống kê.

Lời thoại gợi ý

Bảng này dùng để tra cứu khi chuẩn bị hoặc khi bị hỏi về một hướng cụ thể. Đọc theo hàng: hướng đã thử, con số quan trọng nhất so với đối chứng mạnh nhất, và kết luận. Chỉ H8 và H10 thành công; F và H3 có điều kiện; T và SID-News chưa đo.

Độ lớn tác động của từng họ (Δ nDCG@10)



Mỗi thanh so với đối chứng của chính nó (ghi trong nhãn). Biểu đồ dùng để thấy chiều và độ lớn; không so trực tiếp giữa các họ. Màu: xanh = thành công, vàng = có điều kiện, đỏ = không hiệu quả.

Lời thoại gợi ý

Biểu đồ cho thấy độ lớn. Các thanh dương lớn nhất đều thuộc tầng tổng hợp lịch sử và dữ liệu đầu vào. Các hướng dùng LLM để sinh hoặc nén biểu diễn nằm ở phía âm; Semantic ID giảm tới 0.1011 nên thanh bị cắt bớt. F xuất hiện hai lần để cho thấy vì sao nó chỉ có điều kiện: dương với Qwen3, âm với BGE.

Vì sao nhiều hướng LLM không hiệu quả trên MIND?

1. Nén hoặc viết lại biểu diễn bài báo

GraphRAG thay bài bằng tâm cụm, Semantic ID lượng tử hóa thành mã rời rạc, LLM viết lại lịch sử và hồ sơ thành đoạn văn. Khi 82.25% click là bài mới, mất chi tiết riêng của từng bài là mất điểm (GraphRAG: Cold AUC -0.0181).

2. Chỉ thắng đối chứng yếu

K-Means đa sở thích: $+0.0090$ so với mean pooling nhưng -0.0024 so với LSE. Tháp người dùng LoRA hơn mean pooling nhưng chỉ bằng LSE. LSE không tham số đã lấy được phần lợi ích này.

3. Validation "ấm" đánh lừa

Ở lần chạy v14, so với mean pooling: kNN RAG $+0.0130$ trên validation nhưng -0.0037 trên test; GraphRAG $+0.0199 \rightarrow -0.0066$; reader + kNN $+0.0653 \rightarrow +0.0302$. Validation có ít bài mới hơn test rất nhiều.

4. Tinh chỉnh với ngân sách nhỏ

Mở khóa 2 tầng cuối BGE-large: $+0.0005$ (không có ý nghĩa), Cold AUC -0.0069. Tháp LoRA chỉ huấn luyện 800 bước (0.5% dữ liệu) và validation vẫn còn tăng: chưa đủ để kết luận về bản thân phương pháp.

Lời thoại gợi ý

Bốn mẫu thất bại lặp lại nhiều lần. Một: nén hoặc viết lại biểu diễn làm mất chi tiết của bài mới. Hai: nhiều hướng chỉ thắng mean pooling, còn LSE không tham số đã làm được điều đó. Ba: validation có ít bài mới nên đánh giá quá cao các mô hình mạnh ở bài cũ. Bốn: tinh chỉnh trong ngân sách GPU nhỏ chưa đủ để thay đổi kết quả.

RQ1 · Baseline huấn luyện lại: GloVe là yếu tố quyết định

Thang ablation của NRMS trên MIND-small (mỗi bậc thêm một thay đổi vào bậc trước):

Bậc	Thay đổi so với bậc trước	AUC	nDCG@10	Δ nDCG@10 [CI 95%]
0 `ladder0`	công thức V10 cũ, cài đặt lại	0.6156	0.3694	mốc
1 `ladder1`	tách từ regex, mask padding, bốc lại negative	0.6102	0.3661	-0.0033 $[-0.0051, -0.0015]$
2 `ladder2`	cỡ như bài báo (300 chiều, 16 đầu), vector từ ngẫu nhiên	0.5818	0.3447	-0.0213 $[-0.0229, -0.0197]$
3 `nrms_ref`	**khởi tạo vector từ bằng GloVe-300**	**0.6392**	**0.3937**	$+$**0.0490** $[+0.0471, +0.0509]$
4 `nrms_ref_refit`	huấn luyện thêm các ngày validation	0.6555	0.4078	$+0.0141$ $[+0.0126, +0.0156]$

- Bậc 2 **chưa hội tụ**, nên $+0.0490$ có phần phóng đại; GloVe vẫn là yếu tố lớn nhất.
- Huấn luyện lại đúng cách nâng NRMS từ 0.3694 (công thức V10) lên 0.3937 (một seed) và 0.4078 (refit); so sánh với embedding cố định ở slide sau.

Ý chính. baseline yếu ở V10 là do công thức huấn luyện, không do mô hình: thêm GloVe là bước tăng lớn nhất.

Lời thoại gợi ý

Trước khi đánh giá LLM, nhóm phải có baseline đúng. NRMS theo công thức cũ yếu vì thiếu vector từ huấn luyện sẵn; thêm GloVe là bước tăng lớn nhất. Lưu ý bậc 2 chưa hội tụ nên con số 0.049 có phần phóng đại. Kết quả RQ1: embedding cố định chỉ ngang, chưa vượt NRMS refit, vì khoảng tin cậy chứa 0.

RQ1 · NRMS, NAML, Fastformer huấn luyện lại so với embedding cố định

Mô hình (MIND-small)	Học?	AUC	nDCG@10	Cold AUC	Nguồn
NRMS, seed 0	có	0.6392	0.3937	0.6471	v7
NRMS, seed 1	có	0.6501	0.4005	0.6630	v7
NAML	có	0.6471	0.4006	0.6698	v7
Fastformer (trung bình 2 seed)	có	0.6426	0.3927	0.6623	v13
NRMS refit (học thêm các ngày validation)	có	0.6555	0.4078	0.6700	v7
Fastformer refit	có	0.6550	0.4033	0.6767	v13
BGE-small + LSE (H8)	không	0.6386	0.4037	0.6675	v7
Qwen3 + chuyên mục + LSE (F, H8)	không	0.6556	**0.4094**	0.6637	v13

- LSE hơn NRMS seed 0 (+0.010) và Fastformer (+0.011), ngang NAML và NRMS seed 1 (+0.003; hai seed NRMS lệch nhau 0.0068); thua NRMS refit -0.0041 $[-0.0061, -0.0021]$.
- Qwen3 + chuyên mục + LSE ngang NRMS refit (+0.0016, CI chứa 0), hơn Fastformer refit $+0.0061$ $[+0.0022, +0.0100]$.

GloVe-300, công thức bài gốc. V10 cũ: NRMS 0.3685, NAML 0.3953, Fastformer 0.3642. Bài báo (thứ cấp): NRMS 0.410–0.412, NAML 0.412–0.415.

Ý chính. (RQ1) embedding cố định + LSE **ngang** NRMS, NAML, Fastformer học lại; chỉ NRMS refit hơn.

Lời thoại gợi ý

Đây là câu trả lời đầy đủ cho RQ1. Cả ba baseline NRMS, NAML, Fastformer đều được huấn luyện lại theo công thức bài gốc với GloVe. Embedding cố định cộng LSE, không học tham số nào, ngang các baseline huấn luyện một lần; chỉ NRMS khi được học thêm các ngày validation là còn hơn. Bản zero-shot tốt nhất, Qwen3 cộng chuyên mục cộng LSE, ngang NRMS refit và hơn Fastformer refit có ý nghĩa thống kê.

RQ2 · Bộ mã hóa lớn hơn không giúp mean pooling

Cố định cách tổng hợp là mean pooling, đổi bộ mã hóa (MIND-small):

Bộ mã hóa (số chiều)	**nDCG@10**	**Δ so với BGE-small**
TF-IDF + LSA (256)	0.3467	−0.0443
BGE-base (768)	–	−0.0185
Qwen3-Embedding-0.6B (1024)	0.3784	−0.0125
BGE-small (384)	0.3909	mốc
BGE-large (1024)	0.3924	+0.0015 (n.s.)

- Tăng khoảng 10 lần số tham số (BGE-small → BGE-large) chỉ được +0.0015, không có ý nghĩa; BGE-base còn kém BGE-small.
- Trên MIND-large, khi làm đầu vào cho reader, BGE-large (335M tham số) vẫn hơn Qwen3-Embedding-0.6B: $+0.0102\ [+0.0095, +0.0108]$.
- Khoảng cách tới NRMS refit (0.4078) nằm ở **cách tổng hợp**: mean pooling chia đều mọi bài đã đọc, còn NRMS học attention để lọc nhiễu.

Ý chính. (RQ2) điểm nghẽn là tầng tổng hợp lịch sử đọc, không phải kích thước bộ mã hóa. Vì vậy phần 5 bắt đầu từ H8 và H10.

Lời thoại gợi ý

Nếu LLM lớn hơn tự động tốt hơn thì Qwen3 0.6B phải hơn BGE-small; thực tế ngược lại. Tăng kích thước BGE lên 10 lần cũng gần như không đổi. Vậy phần đáng cải thiện là cách gộp lịch sử đọc thành điểm số, và đó là chỗ H8, H10 tác động.

H8 · Vì sao mean pooling làm loãng sở thích ngách

$$s_{\text{mean}}(u,c) = \frac{1}{|\mathcal{H}_u|}\sum_{i\in\mathcal{H}_u}\langle \mathbf{v}_i, \mathbf{v}_c\rangle \qquad \text{và} \qquad s_{\text{LSE}}(u,c) = \tau\Big(\log\sum_{i\in\mathcal{H}_u}\exp\left(\langle \mathbf{v}_i, \mathbf{v}_c\rangle/\tau\right) - \log|\mathcal{H}_u|\Big)$$

Mean pooling: tín hiệu bị pha loãng

Lịch sử: 40 bài thể thao ($\langle \mathbf{v}_i, \mathbf{v}_c\rangle \approx 0.1$) và 5 bài tài chính ($\approx 0.8$).

Ứng viên là bài tài chính: $s_{\text{mean}} = \frac{40\cdot 0.1 + 5\cdot 0.8}{45} \approx$ **0.178**: bị 40 bài thể thao lấn át.

LSE (smooth-max, ví dụ $\tau = 0.1$)

Khuếch đại theo hàm mũ $\exp(\langle \mathbf{v}_i, \mathbf{v}_c\rangle/\tau)$ trước khi cộng, nên vài bài rất giống ứng viên chiếm ưu thế.

Cùng ứng viên: $s_{\text{LSE}} \approx$ **0.58**: giữ được sở thích ngách.

- Độc giả đọc nhiều chủ đề: độ tương đồng cao với vài bài cùng chủ đề bị chia nhỏ theo hệ số $1/|\mathcal{H}_u|$.
- LSE nằm giữa trung bình (τ lớn) và MaxSim ($\tau \to 0$); τ thực tế chọn trên validation (số trong hai khung chỉ là ví dụ). Top-k (trung bình k bài giống nhất) có cùng ý tưởng.

Ý chính. H8 không thêm tham số học nào; chỉ thay cách gộp các độ tương đồng giữa ứng viên và từng bài đã đọc.

Lời thoại gợi ý

Ví dụ: độc giả đọc 40 bài thể thao và 5 bài tài chính. Với ứng viên tài chính, mean pooling cho điểm thấp vì 40 bài thể thao kéo trung bình xuống. LSE khuếch đại các bài rất giống ứng viên nên giữ được sở thích ngách. Đây là thay đổi không có tham số học.

H8 · Kết quả: LSE và top-k tăng ổn định, không cần huấn luyện

Toán tử tổng hợp (không tham số)	Ý tưởng	MIND-small BGE-small	MIND-large BGE-large	Δ MIND-large [CI 95%] so với mean pooling
`frozen` (đối chứng)	trung bình mọi bài đã đọc	0.3909	0.3933	mốc
`pool_recency`	trọng số giảm theo thời gian	0.3917	0.3933	−0.0000 [−0.0002, +0.0001]
`pool_maxsim`	chỉ lấy bài giống nhất ($k = 1$)	0.3941	0.3916	−0.0017 [−0.0025, −0.0009]
`pool_km5` (H11)	gom lịch sử thành 5 cụm	0.4007	0.4023	+0.0090 [+0.0085, +0.0094]
`pool_topk`	**trung bình k bài giống nhất**	**0.4016**	**0.4045**	**+0.0111** [+0.0105, +0.0118]
`pool_lse`	**smooth-max (LogSumExp)**	**0.4037**	**0.4047**	**+0.0113** [+0.0107, +0.0119]

- Lặp lại trên Qwen3-Embedding (MIND-large): top-k +0.0143, LSE +0.0130. Cold AUC của LSE cũng tăng (BGE-large 0.6632 → 0.6713).
- MaxSim cứng nhạy với các click nhiễu đơn lẻ; K-Means luôn nằm giữa mean pooling và LSE (xem H11).
- Trên MIND-small, LSE thu hẹp khoảng 3/4 khoảng cách giữa BGE-small mean pooling (0.3909) và NRMS refit (0.4078).

Ý chính. THÀNH CÔNG tăng ổn định trên 2 encoder, 2 quy mô, không tốn tham số; từ đây LSE là *đối chứng mạnh*.

Lời thoại gợi ý

Trên cả hai quy mô và hai bộ mã hóa, LSE và top-k đều tăng khoảng 0.011 đến 0.014 nDCG@10 mà không học gì thêm. MaxSim cứng thì giảm vì quá nhạy với một click nhiễu. Từ đây, LSE được dùng làm đối chứng mạnh: một hướng mới phải hơn LSE mới được coi là có ích.

H8 so với attention học được trên cùng vector cố định

Cách tổng hợp lịch sử	Tham số	MIND-small		MIND-large	
		BGE-small	Qwen3	BGE-large	Qwen3
mean pooling	không	0.3909	0.3784	0.3933	0.3787
LSE (H8)	không	**0.4037**	0.3912	0.4047	0.3916
reader kiểu NRMS	có	0.3862	–	–	–
reader kiểu Fastformer	có	0.3939	0.3944	–	–
reader $K = 4$ truy vấn (H11)	có	0.3944	**0.4029**	–	–
reader theo ứng viên (H10)	có	0.3968	0.3996	0.4152	0.4050
reader theo ứng viên + kNN	có	0.4033	–	**0.4189**	**0.4095**

Test nDCG@10, cùng bảng embedding cố định. Trung bình 2–3 seed (kiểu NRMS, + kNN trên MIND-small: 1 seed). Nguồn v7, v13, v16b; "–": chưa chạy hoặc log không ghi.

- **BGE-small, MIND-small:** LSE hơn mọi reader học được, +0.007 đến +0.018 (reader + kNN chỉ ngang).
- **Qwen3 hoặc MIND-large:** reader theo ứng viên hơn LSE, +0.008 đến +0.013.
- Kiểu attention ít quan trọng hơn encoder và lượng dữ liệu; reader kiểu NAML chưa chạy riêng.

Ý chính. trong nhóm không tham số, LSE tốt nhất; so với attention học được thì tùy encoder và lượng dữ liệu.

Lời thoại gợi ý

Slide này trả lời câu hỏi: LSE có thắng được attention học được không. Trên cùng vector cố định, nhóm thử reader kiểu NRMS, kiểu Fastformer, nhiều truy vấn và theo ứng viên. Với BGE-small trên MIND-small, LSE thắng tất cả. Nhưng với Qwen3, và khi có nhiều dữ liệu ở MIND-large, reader theo ứng viên thắng LSE. Kiểu attention cụ thể không quan trọng bằng encoder và lượng dữ liệu. Ví dụ trên BGE-small, LSE hơn reader 4 truy vấn +0.0093, CI [+0.0075, +0.0112]; với Qwen3 trên MIND-small, cả hai seed của reader theo ứng viên đều trên LSE. Hệ thống cuối vì vậy dùng cả hai: reader làm nền, LSE làm thành phần phụ. Reader kiểu NAML chưa được chạy riêng; NAML chỉ được chạy như baseline đầy đủ ở phần RQ1.

H10 · Reader: dùng ứng viên làm câu hỏi để đọc lịch sử

Tầng nhẹ có huấn luyện, đặt trên bảng embedding cố định **E**:

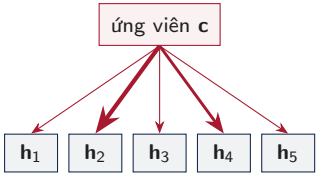
- **Reader theo ứng viên** (`um_frozen`, `um_knn_rag`): chiếu vector qua MLP hai tầng, $\mathbf{h}_i = f(\mathbf{E}_{\text{hist},i})$, $\mathbf{c} = f(\mathbf{E}_{\text{cand}})$, rồi dùng **c** làm truy vấn:

$$\alpha_i = \text{softmax}_i\Big(\frac{\langle \mathbf{W}_c\mathbf{c}, \mathbf{h}_i\rangle}{\sqrt{d}}\Big), \quad s_{\text{CA}}(u,c) = \Big\langle \textstyle\sum_i \alpha_i \mathbf{h}_i,\ \mathbf{c}\Big\rangle.$$

- **Reader nén một vector** (`um_nrms`, `um_ff`): khối NRMS hoặc Fastformer nén cả lịch sử thành một vector **u** trước khi biết ứng viên.
- **Prior** (`um_prior`): chỉ nhìn bài báo; làm đặc trưng cho GBDT.

Huấn luyện: softmax trên bài được click và các bài không được click cùng lượt:

$$\mathcal{L} = -\log \frac{\exp s(u,c^+)}{\exp s(u,c^+) + \sum_{c^-} \exp s(u,c^-)}.$$



nét càng đậm: trọng số α_i càng lớn
(bài cùng chủ đề với ứng viên)

Lời thoại gợi ý

Reader là phiên bản có học của ý tưởng H8. Thay vì công thức cố định, nó học trọng số attention lên từng bài đã đọc, với chính ứng viên là câu hỏi. Có hai kiểu: theo ứng viên, và nén lịch sử thành một vector trước như NRMS. Câu hỏi là học như vậy có hơn LSE không; kết quả phụ thuộc encoder và lượng dữ liệu.

H10 · Reader theo ứng viên hơn LSE trên MIND-large và trên Qwen3

Reader theo ứng viên so với LSE, cùng encoder (test nDCG@10):

Thiết lập	LSE	Reader	Δ
MIND-small, BGE-small	0.4037	0.3968	−0.0069
MIND-small, Qwen3	0.3912	0.3996	+0.0084
MIND-large, BGE-large	0.4047	0.4152	**+0.0105**
MIND-large, Qwen3	0.3916	0.4050	**+0.0134**
MIND-large, vector nối	–	**0.4223**	–

Reader: trung bình 3 seed (BGE-small) hoặc 2 seed; hai seed lệch nhau 0.001–0.013. Δ của BGE-large là ghép cặp (v16b); các Δ khác tính từ hai con số.

- Với BGE-small và ít dữ liệu, reader chưa hơn LSE. Với Qwen3, hoặc trên MIND-large (dữ liệu gấp khoảng 14 lần), reader hơn LSE.
- Trên vector nối hai encoder, reader đạt **0.4223**; bản có kNN (`cat:um_knn_rag`) là nền của hệ thống.

Cảnh báo validation ấm

Lần chạy v14 (Qwen3), so với mean pooling: reader + kNN **+0.0653** trên validation nhưng chỉ **+0.0302** trên test.

Ý chính. THÀNH CÔNG H10 hơn LSE trên MIND-large (+0.0105 đến +0.0134) và trên Qwen3, là thành phần mạnh nhất của hệ thống. Với BGE-small trên MIND-small thì chưa hơn LSE.

Lời thoại gợi ý

Kết quả của H10 phụ thuộc encoder và lượng dữ liệu. Với BGE-small trên MIND-small, reader chưa hơn LSE. Với Qwen3, reader đã hơn LSE ngay trên MIND-small; và trên MIND-large, với khoảng 14 lần dữ liệu, reader hơn LSE trên cả hai encoder và trở thành thành phần chính của hệ thống. Cần nhớ validation thổi phồng lợi ích của reader, nên mọi kết luận ở đây dựa trên test.

Không gian biểu diễn: ghép hai encoder; kNN chủ yếu giúp bài mới

Test nDCG@10 trên MIND-large, trung bình 2 seed, cùng đầu reader 128 chiều:

Reader	Qwen3	BGE-large	Nối (2048)
theo ứng viên (`um_frozen`)	0.4050	0.4152	**0.4223**
+ kNN (`um_knn_rag`, H3)	0.4095	0.4189	**0.4226**
đọc văn bản có chuyên mục (`um_text`)	0.4092	–	–

Vector nối: $\mathbf{e} = [\mathbf{e}_{\text{Qwen3}} \,\|\, \mathbf{e}_{\text{BGE}}]/\sqrt{2}$. kNN: $\mathbf{e}'_c = \text{Norm}(\mathbf{e}_c + \beta\,\text{Norm}(\sum_{j\in\mathcal{N}_k(c)} s_{cj}\mathbf{e}_j))$, chỉ dùng các bài có trước thời điểm đánh giá. Hai seed của cùng reader lệch 0.001–0.008.

- BGE-large hơn Qwen3 $+0.0102$ $[+0.0095, +0.0108]$; vector nối hơn BGE-large $+0.0071$ $[+0.0066, +0.0076]$: **đa dạng hai không gian** có ích hơn kích thước.
- kNN trong reader: $+0.0045$ (Qwen3), $+0.0037$ (BGE-large), nhưng trên vector nối chỉ $+0.0003$ $[-0.0001, +0.0007]$; Cold AUC vẫn tăng $+0.0088$.
- RAG dùng thẳng, không qua reader (BGE-large, so với mean pooling): thực thể -0.0105, kNN -0.0017, GraphRAG -0.0079.

Ý chính. CÓ ĐIỀU KIỆN H3: kNN chỉ có ích khi đi qua reader và chủ yếu ở bài mới; vector nối hai encoder là không gian tốt nhất cho reader.

Lời thoại gợi ý

Bảng cho thấy ba điều. BGE-large tốt hơn Qwen3 khi làm đầu vào cho reader, và ghép hai encoder còn tốt hơn nữa. kNN giúp trên từng encoder nhưng gần như hết tác dụng trên vector nối, dù vẫn tăng Cold AUC. Còn dùng RAG trực tiếp không qua reader thì đều giảm.

F · Thêm chuyên mục vào văn bản: giúp Qwen3, không giúp BGE

MIND không có toàn văn: tóm tắt trung bình 34.9 từ (5.2% rỗng), tiêu đề 10.7 từ; 18 chuyên mục, 270 chuyên mục con. Mẫu cta: `"Category: {cat}. Subcategory: {subcat}. {title}. {abstract}"`.

Thay đổi văn bản (Δ nDCG@10 so với LSE cùng encoder)	**Qwen3, small**	**BGE, small**	**Qwen3, large**	**BGE, large**
chỉ tiêu đề (bỏ tóm tắt)	−0.0321	−0.0161	–	–
+ chuyên mục (cta)	**+0.0182**	+0.0013	**+0.0186**	−0.0024
+ tên thực thể (ctae so với cta)	–	+0.0033	–	–
lịch sử 100 click thay vì 50	+0.0013	+0.0011	–	–

- Qwen3: validation cùng chiều với test (+0.0129 và +0.0182); BGE: validation ngược chiều (−0.0096), không ổn định.
- Phần tăng của Qwen3 nằm ở bài đã biết (Warm AUC 0.4939 → 0.6180); Cold AUC gần như không đổi (+0.0005, n.s.); với BGE-large, Cold AUC giảm −0.0277.
- Tóm tắt rất quan trọng (bỏ đi: −0.016 đến −0.032); lịch sử dài hơn gần như không giúp.

Ý chính. CÓ ĐIỀU KIỆN F giúp encoder nhận chỉ dẫn dạng văn bản (Qwen3), không giúp BGE, không giúp bài mới; `qwen3:txt_cta_lse` vẫn là thành phần zero-shot mạnh nhất.

Lời thoại gợi ý

Nhóm kiểm tra xem dùng thêm trường dữ liệu có giúp không. Chuyên mục giúp Qwen3 khoảng 0.018 ở cả hai quy mô, nhưng không giúp BGE, và phần tăng nằm ở bài đã biết chứ không ở bài mới. Tóm tắt thì rất quan trọng; lịch sử dài hơn gần như không đổi.

H2, H12 · Tinh chỉnh bộ mã hóa không mang lại lợi ích rõ

H2 (MIND-small): LoRA / DoRA cho encoder, Matryoshka InfoNCE, hard negative từ impression, học trên cặp bài cùng được click: **+0.0016 đến +0.0029** nDCG@10 so với mean pooling, Cold AUC giảm; thêm head MLP −0.005.

H12 (MIND-large, v17): cache trạng thái ẩn tầng 22 của BGE-large (fp16 ≈ 20.5 GB), mở khóa 2 tầng cuối, huấn luyện cùng reader 18.000 bước; nhánh đối chứng giữ đóng băng, cùng số bước, cùng thứ tự mẫu.

Nhánh	BGE-large	Val (trọng số bài mới)	Test AUC	Test nDCG@10	Cold AUC
`ft_base` (đối chứng)	giữ đóng băng	0.4476	0.6736	0.4208	0.6883
`ft_reader`	mở khóa 2 tầng cuối	0.4480	0.6710	0.4213	0.6814

- Δ nDCG@10 $= +0.0005$ $[-0.0001, +0.0010]$: không có ý nghĩa; Δ Cold AUC $= -0.0069$ $[-0.0074, -0.0065]$.
- Cổng dừng đăng ký trước khi chạy yêu cầu ít nhất $+0.006$: **không qua**. Có thể mô hình khớp vào bài cũ và mất tính tổng quát cho bài mới (chưa kiểm chứng trực tiếp).

Ý chính. KHÔNG HIỆU QUẢ H2 và H12, trong ngân sách đã thử: lợi ích nDCG không đáng kể, còn Cold AUC giảm.

Lời thoại gợi ý

Đây là thí nghiệm gần nhất với cách làm của PLM-NR: mở khóa hai tầng cuối của BGE-large và huấn luyện cùng reader, có nhánh đối chứng đóng băng chạy cùng điều kiện. Kết quả gần như bằng nhau, Cold AUC còn giảm, và không qua ngưỡng $+0.006$ đã đặt trước. Vì vậy nhóm không đưa tinh chỉnh vào hệ thống cuối.

H5 · Tháp người dùng LLM (LoRA): chỉ ngang LSE

Thiết lập: Qwen3-Embedding-0.6B đọc lịch sử dưới dạng văn bản, tinh chỉnh bằng LoRA (mặt nạ causal, bidirectional hoặc soft). MIND-large: 800 bước × 16 mẫu = 12.800 mẫu (0.5% dữ liệu huấn luyện), validation vẫn còn tăng ở bước cuối; do chi phí suy luận, chỉ đánh giá trên 30.000 impression test.

Biến thể (v14)	Mô tả	AUC	nDCG@10	Δ nDCG@10 [CI 95%]	so với
`ut_causal`	tháp LoRA đứng riêng	0.6272	0.3807	$+0.0065$ $[+0.0035, +0.0095]$	mean pooling
`ut_causal+meanpool`	tháp + mean pooling	0.6384	0.3904	$+0.0162$ $[+0.0138, +0.0187]$	mean pooling
				-0.0000 $[-0.0027, +0.0026]$	**LSE**
`super_apex`	bộ hợp nhất + tháp	0.6743	0.4223	-0.0002 $[-0.0009, +0.0006]$	bộ hợp nhất

- MIND-small: tháp + mean pooling ≈ LSE của BGE (-0.0007, n.s.), thua NRMS refit (-0.0035). Khác biệt giữa các mặt nạ nhỏ hơn nhiễu seed (0.010–0.012); mặt nạ soft không lặp lại được (0.4043 → 0.3956).

Ý chính. KHÔNG HIỆU QUẢ H5 hơn mean pooling nhưng chỉ bằng LSE không tham số và không thêm gì khi hợp nhất. Ngân sách huấn luyện quá nhỏ nên chưa kết luận được về bản thân phương pháp.

Lời thoại gợi ý

Tháp người dùng LLM là hướng trông hứa hẹn trong văn liệu. Ở đây nó hơn mean pooling, nhưng khi so với LSE thì bằng nhau, và thêm vào bộ hợp nhất không đổi gì. Cần nói rõ: mô hình chỉ được huấn luyện 800 bước, nên đây là kết luận trong ngân sách đã thử, chưa phải kết luận về phương pháp.

H11 · Đa sở thích: tách được sở thích nhưng không tăng điểm

K-Means zero-shot (`pool_kmK`): gom lịch sử thành K cụm rồi chấm bằng LSE; $K = 1$ là mean pooling, K đủ lớn chính là LSE.

MIND-small: $K = 2/3/5$ cho 0.3958 / 0.3989 / 0.4007, luôn giữa mean pooling (0.3909) và LSE (0.4037). MIND-large: $K = 5$ cho 0.4023, thấp hơn LSE (0.4047).

Reader $K = 4$ truy vấn (`um_mi4`): mỗi truy vấn đọc lịch sử theo một sở thích; bản `mi4d` thêm phạt $\lambda \cos^2(\mathbf{u}_k, \mathbf{u}_l)$ giữa các vector sở thích để chúng tách nhau.

BGE-small, 3 seed	nDCG@10	cos	TV
`um_frozen` (1 vector)	0.3968	–	–
`mi1` ($K = 1$, đối chứng)	0.3906	–	–
`mi4` ($K = 4$, không phạt)	0.3944	0.85–0.87	0.33–0.34
`mi4d` ($K = 4$, có phạt)	0.3972	0.34–0.39	0.71–0.72

cos: tương đồng trung bình giữa các vector sở thích; TV: khoảng cách giữa các phân phối attention.

Không phạt: 4 vector gần như trùng nhau (cos 0.85–0.87; MIND-large 0.94–0.96). Có phạt: tách ra nhưng không tăng điểm (so với 1 vector: BGE +0.0004, n.s.; Qwen3 −0.0031).

Ý chính. KHÔNG HIỆU QUẢ H11: LSE chính là trường hợp K lớn của K-Means; phạt đa dạng làm sở thích tách nhau nhưng không giúp xếp hạng.

Lời thoại gợi ý

Đa sở thích là hướng rất tự nhiên với độc giả đọc nhiều chủ đề. Nhưng K-Means luôn kém LSE, vì LSE chính là trường hợp có rất nhiều cụm. Reader nhiều truy vấn thì sụp đổ về một sở thích; thêm phạt đa dạng thì tách được, nhưng điểm xếp hạng không tăng.

H1, H4, H6, H7, H9 · Sinh văn bản hoặc nén biểu diễn bằng LLM

Họ	Cách làm	Kết quả (Δ nDCG@10)	Giải thích khả dĩ
H1: lịch sử thành văn bản	ghép các tiêu đề đã đọc thành một câu truy vấn	-0.0211 đến -0.0014 (MIND-small)	câu dài làm loãng tín hiệu từng bài
H6: hồ sơ độc giả	Qwen3-1.7B viết hồ sơ sở thích	-0.0308 (MIND-small)	tóm tắt mất sở thích ngách
H6: mô tả bài	LLM viết mô tả mở rộng mỗi bài	$+0.0079$ $[+0.0021, +0.0137]$, $n = 2.500$; mất khi có popularity	trùng với độ phổ biến
H9: LLM chấm điểm	Qwen3-1.7B hỏi Yes/No từng ứng viên	-0.0112 $[-0.0216, -0.0008]$, $n = 2.000$	thiếu hiệu chuẩn; chậm
H7: Semantic ID	mã RQ-KMeans; xếp hạng sinh SID-GPT	hồ sơ SID $+0.0035$; SID-GPT $0.2898 \approx$ ngẫu nhiên 0.2897	chưa học được; cần kiểm tra cài đặt
H4: GraphRAG	thay bài bằng tâm cụm của đồ thị kNN	small $+0.0043$; large: val $+0.0199$, test -0.0066	tâm cụm xóa chi tiết riêng của bài mới
H4b: tóm tắt cụm	LLM viết tóm tắt chủ đề mỗi cụm	không khác biệt thống kê	–

Ý chính. KHÔNG HIỆU QUẢ không hướng nào cho lợi ích bền vững trên test. Riêng SID-GPT ngang vector ngẫu nhiên: cần kiểm tra lại cài đặt trước khi kết luận về Semantic ID.

Lời thoại gợi ý

Nhóm các hướng dùng LLM để viết lại hoặc nén biểu diễn đều không đứng vững. Riêng Semantic ID, mô hình sinh cho kết quả ngang vector ngẫu nhiên; đây là dấu hiệu nó không học được gì, nên nhóm thận trọng: kết luận là "chưa làm được trong cài đặt này", chưa phải "phương pháp không dùng được".

Hướng đề xuất chưa có số đo: SID-News và cổng cold/warm

SID-News: sửa các điểm yếu của H7

Giả thuyết vì sao H7 cơ sở thất bại: (1) mã RQ-KMeans tĩnh làm mất thông tin chuyên mục; (2) lịch sử có nhiều click nhiễu (tiêu đề câu khách); (3) giải mã tự do sinh ra mã không có trong danh sách ứng viên.

Thiết kế đề xuất:

1. Bổ sung chuyên mục: $\mathbf{E}_{\text{fused}} = \text{Norm}(\mathbf{E}_0 + 0.20\,\mathbf{E}_{\text{cat}})$.
2. $K = 4$ truy vấn sở thích, chấm điểm bằng LSE ($\tau = 5.0$) để giảm ảnh hưởng click nhiễu.
3. Giải mã ràng buộc bằng cây tiền tố (trie): chỉ sinh mã có trong lượt hiển thị.

Họ T: tách ngữ nghĩa và cộng tác

- Mô tả ngữ nghĩa của chuyên mục do LLM viết (theo Yada & Yamana, 2024).
- Cổng kiểu PAD: $s = (1 - g_c)\, s_{\text{sem}} + g_c\, s_{\text{collab}}$; với bài mới, $g_c \to 0$ nên điểm dựa vào nhánh ngữ nghĩa.
- Adaptor dư kiểu KAR đưa tri thức bổ sung vào vector bài.

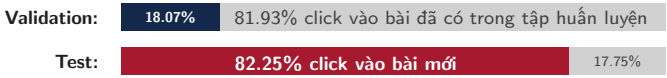
Trạng thái: CHƯA ĐO

Đã có mã (`stages_innov.py`, notebook v8) nhưng **chưa có lần chạy đo kết quả**, nên không xếp vào thành công hay thất bại.

Lời thoại gợi ý

Hai hướng này là đề xuất cho bước tiếp theo, chưa phải kết quả. Nhóm nêu rõ để tránh hiểu lầm: chúng đã có mã nhưng chưa có lần chạy nào đo được. Nếu hội đồng hỏi, câu trả lời là chúng được thiết kế từ chính các thất bại của H7 và từ quan sát về bài mới.

Validation và test khác nhau: 18% so với 82% click vào bài mới



Lợi ích so với mean pooling trên validation và trên test (lần chạy v14, Qwen3):

Thành phần	Validation	Test
LSE (H8)	+0.0232	+0.0146
văn bản có chuyên mục (F)	+0.0370	+0.0315
kNN RAG dùng thẳng (H3)	+0.0130	**−0.0037**
GraphRAG (H4)	+0.0199	**−0.0066**
reader theo ứng viên (H10)	+0.0596	+0.0192
reader + kNN	+0.0653	+0.0302

- Validation là ngày cuối của tập huấn luyện nên "ấm": phần lớn click rơi vào bài đã biết.
- Thành phần không huấn luyện giữ được phần lớn lợi ích; reader mất hơn một nửa; RAG và GraphRAG **đổi dấu**.
- Chọn mô hình theo trung bình validation thông thường vì vậy ưu ái mô hình mạnh ở bài cũ.

Lời thoại gợi ý

Đây là phát hiện quan trọng về đánh giá. Validation có chưa tới 20% click vào bài mới, test có hơn 80%. Hệ quả là các thành phần mạnh ở bài cũ, như reader hay RAG, trông tốt trên validation hơn hẳn trên test; RAG và GraphRAG còn đổi dấu. Nếu chọn mô hình theo validation thông thường, ta sẽ chọn sai.

Validation có trọng số theo tỷ lệ bài mới

Gán trọng số w_i cho từng impression theo tỷ lệ click vào bài mới $c_i \in [0, 1]$ của nó, để tỷ lệ bài mới hiệu dụng chuyển từ $\bar{c}_{\text{val}} = 0.1807$ về mục tiêu $\tau = 0.80$:

$$w_i = \frac{\tau}{\bar{c}_{\text{val}}} c_i + \frac{1 - \tau}{1 - \bar{c}_{\text{val}}} (1 - c_i).$$

Bằng chứng: chọn đúng mô hình

- v15, validation thông thường: chọn `qwen3:um_text` làm nền (val 0.4090 so với 0.4079 của `um_knn_rag`), nhưng trên test `um_knn_rag` tốt hơn (0.4097 so với 0.4026): **chọn sai**.
- v16b, validation có trọng số: chọn `cat:um_knn_rag` (0.4573), cũng là thành phần tốt nhất trên test.

Giới hạn

- $\tau = 0.80$ được chọn gần tỷ lệ quan sát trên test, vốn tính từ nhãn test ở mức tổng hợp. Nên thay bằng ước lượng không dùng nhãn, ví dụ tỷ lệ ứng viên mới trong impression.
- Trọng số giúp chọn đúng, nhưng không làm con số validation khớp test (test thấp hơn 0.030–0.081).

Lời thoại gợi ý

Cách sửa đơn giản: tăng trọng số các impression có nhiều click vào bài mới để validation giống test hơn. Ở v15, validation thông thường chọn nhầm reader; ở v16b, validation có trọng số chọn đúng thành phần tốt nhất. Cần thừa nhận giới hạn: tham số 0.80 được đặt gần tỷ lệ quan sát trên test.

Hợp nhất tuyến tính: một reader và ba thành phần zero-shot là đủ

Điểm mỗi thành phần chuẩn hóa z-score trong từng impression; trọng số chọn bằng coordinate ascent trên validation có trọng số bài mới.

Bậc	Thành phần được chọn (trọng số)	Val	AUC	nDCG@10	Cold AUC
`super_base`	`cat:um_knn_rag`, trung bình z-score của 2 seed	0.4573	0.6768	0.4260	0.7104
`super_zs`	+ `bge:hist100_lse` 0.1, `bge:pool_lse` 0.1, `qwen3:txt_cta_lse` 0.25	0.4676	0.6863	**0.4373**	0.7185
`super_llm`*	+ `bge:ft_reader` 0.1 (H12, lần chạy v17)	0.4679	0.6869	0.4378	0.7181
`super_llm+pop`	`super_zs` + popularity online 1.0	0.4927	0.7133	0.4638	0.7539

- `super_base` cao hơn chính reader của nó (0.4226) nhờ trung bình hai seed (+0.0034).
- Thêm ba thành phần zero-shot: +0.0114 [+0.0109, +0.0118]; các reader khác được trọng số 0; `ft_reader` (H12) chỉ thêm +0.0005.
- Bỏ nhóm zero-shot khỏi `super_llm+pop`: −0.0092; bỏ popularity: −0.0265.

Ý chính. một reader và ba thành phần zero-shot khác loại cho **0.4373**; thêm reader cùng loại không giúp. Mọi thành phần là embedding và reader; tên `super_llm` trong mã không có nghĩa là dùng LLM sinh.

Val: validation có trọng số bài mới. (*) Lần chạy v17; còn lại v16b (trong mã v16b, `super_zs` mang tên `super_llm`).

Lời thoại gợi ý

Bộ hợp nhất tuyến tính rất đơn giản: chuẩn hóa điểm của từng thành phần rồi cộng có trọng số. Kết quả quan trọng: một reader cộng ba thành phần zero-shot khác loại là đủ, đạt 0.4373; thêm reader cùng loại, kể cả encoder đã tinh chỉnh của H12, gần như không đổi. Đây là mức tốt nhất khi chỉ dùng nội dung và lịch sử.

GBDT stacker: 99 đặc trưng trong 4 nhóm

Vì sao cần GBDT trên các reader và bộ hợp nhất? Hợp nhất tuyến tính dùng một bộ trọng số chung cho mọi ứng viên; GBDT có thể đổi cách kết hợp theo ngữ cảnh, ví dụ theo mức hiển thị (exposure) của từng bài. Các reader không bị thay thế mà trở thành đặc trưng quan trọng nhất.

Nhóm	Số cột	Nội dung
`scores` (điểm thành phần)	59	z-score trong impression và điểm thô của 41 thành phần, chủ yếu các reader trên Qwen3, BGE-large và vector nối
`ctx` (ngữ cảnh slate)	15	tương đồng với click gần nhất (`last1`, `last3`), tỷ lệ trùng chuyên mục, kích thước slate (`ctx_n_cand`), mức trùng thực thể Wikidata có trọng số IDF
`meta` (exposure, offline)	16	thống kê từ tập huấn luyện (`m_ctr`, `m_unseen`) và động thái hiển thị không dùng nhãn: tuổi bài (`m_age_h`), số lần hiển thị trong 1, 6, 24 giờ trước
`pop` (chỉ online)	9	log-CTR tích lũy và CTR theo cửa sổ 1, 6, 24 giờ, tính từ click trước đó trong chính ngày test

Ý chính. ba biến thể: `stack_llm` (`scores` + `ctx`), `stack_meta` (+ `meta`, vẫn là offline) và `stack_pop` (+ `pop`, chế độ online).

Lời thoại gợi ý

GBDT nhận 99 đặc trưng chia làm 4 nhóm. Nhóm meta là thông tin hiển thị của bài lấy từ log mà không dùng nhãn, nên vẫn thuộc chế độ offline. Nhóm pop dùng click của chính ngày test nên chỉ thuộc chế độ online. Ba biến thể tương ứng ba mức thông tin.

Rò rỉ trong ngày: vì sao chia fold theo người dùng là sai

GBDT được huấn luyện trên validation (150.000 impression $\approx$ 6.05 triệu dòng ứng viên). Chia 4 fold theo **người dùng** gây quá khớp vào chính ngày đó:

- **Cơ chế:** các impression cùng thời điểm rơi vào cả phần huấn luyện và phần giữ lại của mỗi fold. Cây sâu ($d = 7$) dùng các cột độ phân giải cao (tuổi bài, số lần hiển thị, kích thước slate) để nhận ra từng bài và nhớ tỷ lệ click của bài đó trong ngày.
- **Dấu hiệu:** điểm out-of-fold cao giả tạo **0.4922**, nhưng chỉ **0.3738** trên các bài chưa xuất hiện trong phần huấn luyện.

Cách sửa: cross-validation theo khối thời gian

1. Chia ngày validation thành **4 khối thời gian liên tiếp**; bỏ một vùng đệm (tối đa 2% độ dài ngày, khoảng 29 phút) ở hai biên của khối giữ lại.
2. Làm thô các cột có thể định danh bài; cấu hình `clean` bỏ thêm các cột hằng trong một impression.
3. Dừng sớm và chọn cấu hình trên **forward holdout** (60% đầu ngày để huấn luyện, 10% để dừng sớm, 30% cuối để đánh giá), tối ưu trên **click vào bài mới**. Cấu hình được chọn là trung bình của `v15` và `clean`.

Lời thoại gợi ý

Lỗi này khó thấy: fold theo người dùng trông hợp lý nhưng các fold cùng một ngày, cùng các bài, nên cây học thuộc độ phổ biến của từng bài trong ngày đó. Dấu hiệu là điểm validation 0.49 nhưng chỉ 0.37 trên bài mới. Cách sửa là chia fold theo khối thời gian và đánh giá trên bài mới.

User-split và time-block CV trên MIND-large

Biến thể	Cách chia fold	Val	Val bài mới	Test	Test − Val
`super_zs`	không dùng GBDT	0.4275	–	0.4373	+0.0098
`stack_meta_v15cfg`	theo người dùng, cây sâu $d = 7$	**0.4922**	**0.3738**	0.4543	**−0.0379**
`stack_llm`	theo khối thời gian	0.4456	0.4109	0.4369	−0.0087
`stack_meta`	theo khối thời gian	0.4588	0.4533	0.4516	−0.0072
`stack_pop`	theo khối thời gian	0.4682	0.4605	0.4731	+0.0049



nDCG@10. Val: điểm out-of-fold trên validation (với `super_zs`: điểm validation thường). Trục ngang của hình tính từ 0. Mọi dòng lấy từ lần chạy v16b.

Ý chính. trên test, cấu hình theo khối thời gian thấp hơn cấu hình theo người dùng −0.0027 [−0.0031, −0.0023]. Lợi ích của nó là **điểm validation đáng tin** (lệch −0.0072 thay vì −0.0379), không phải điểm test cao hơn.

Lời thoại gợi ý

Bảng xác nhận giả thuyết rò rỉ: fold theo người dùng cho điểm validation 0.4922 nhưng test chỉ 0.4543. Fold theo khối thời gian cho validation gần test. Cần nói thẳng: mô hình mới không cao hơn trên test; điều nhóm được là một con số validation mà mình tin được.

Kết quả offline trên MIND-large (376.471 impression test)

Mô hình	Họ / vai trò	Val	AUC	MRR	nDCG@5	nDCG@10	Cold AUC
1. `qwen3:frozen`	mốc (mean pooling)	0.3392	0.6215	0.2922	0.3168	0.3787	0.6583
2. `bge:frozen`	mean pooling, BGE	0.3546	0.6297	0.3042	0.3321	0.3933	0.6632
3. `cat:frozen`	mean pooling, nối	0.3560	0.6379	0.3043	0.3348	0.3945	0.6772
4. `bge:pool_lse`	H8: LSE	0.3743	0.6459	0.3136	0.3441	0.4047	0.6713
5. `qwen3:txt_cta_lse`	F: chuyên mục + LSE	0.3772	0.6554	0.3206	0.3509	0.4102	0.6620
6. `cat:um_knn_rag`	H10 + H3: reader	0.4159	0.6734	0.3255	0.3598	0.4226	0.7065
7. `super_zs`	hợp nhất tuyến tính	0.4275	0.6863	–	–	0.4373	0.7185
8. `stack_llm`	GBDT: điểm, ngữ cảnh	0.4456	0.6853	0.3375	0.3756	0.4369	0.7063
9. `stack_meta`	**GBDT + exposure**	**0.4588**	**0.7013**	**0.3503**	**0.3899**	**0.4516**	**0.7248**
10. `stack_meta_v15cfg`	GBDT, fold người dùng	0.4922	0.7029	0.3528	0.3930	0.4543	0.7285

Mọi dòng lấy từ v16b (dòng 7: log không có MRR, nDCG@5). Val: nDCG@10 trên validation, out-of-fold với GBDT. Dòng 10 chỉ để tham khảo: validation bị thổi phồng do rò rỉ trong ngày.

Ý chính. mô hình offline chính là `stack_meta`: **0.4516** nDCG@10, Cold AUC **0.7248**; tăng +0.0729 so với mốc (dòng 1).

Lời thoại gợi ý

Bảng đọc từ trên xuống theo đúng các tầng: đối chứng, các thành phần đứng vững, hợp nhất, rồi GBDT. Mô hình offline chính là stack_meta với 0.4516. Dòng 10 cao hơn một chút trên test nhưng điểm validation của nó không đáng tin, nên chỉ để tham khảo.

Chế độ online: thêm phản hồi click trong ngày

Mô hình (online)	AUC	MRR	nDCG@10	Cold AUC
`popularity` (chỉ đếm click, không nội dung)	0.6540	0.3126	0.4040	0.6986
`super_llm+pop`	0.7133	0.3604	0.4638	0.7539
`stack_pop`	**0.7196**	**0.3671**	**0.4731**	0.7526

So sánh ghép cặp: `stack_pop` − `stack_meta` = +0.0215 [+0.0209, +0.0220]; `stack_pop` − `super_llm+pop` = +0.0093 [+0.0087, +0.0099].

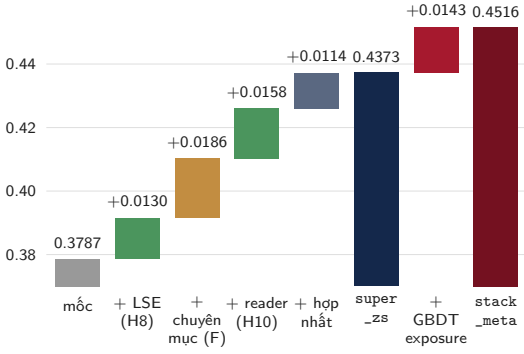
- Các đặc trưng pop dùng click của những impression trước đó **trong chính ngày test** (theo luồng).
- Vì vậy chế độ này **không so trực tiếp** với các mô hình offline hay số công bố, và không thể nộp lên bảng xếp hạng.
- Riêng `popularity`, không dùng nội dung, đã cao hơn mean pooling trên embedding (0.3787–0.3945).

Ý chính. trong triển khai thật, phản hồi theo thời gian thực là nguồn thông tin rất mạnh: `stack_pop` đạt **0.4731** nDCG@10. Đây là con số của chế độ online, tách riêng khỏi kết quả offline.

Lời thoại gợi ý

Chế độ online cho thấy nếu hệ thống được dùng click thời gian thực thì điểm còn tăng mạnh. Nhưng phải tách bạch: đây là thông tin mà các mô hình offline và các bài báo không có, nên không dùng con số này để so với công bố.

Phân rã mức tăng: khoảng 80% từ embedding và reader, 20% từ exposure



Bước	Δ nDCG@10 [CI 95%]
+ LSE	+0.0130 [+0.0123, +0.0136]
+ chuyên mục	+0.0186 [+0.0179, +0.0192]
+ reader	+0.0158 [+0.0150, +0.0165]
+ hợp nhất	+0.0114 [+0.0109, +0.0118]
tổng 4 bước	+0.0586 (80%)
GBDT, exposure	+0.0143 [+0.0137, +0.0149]

- Bản thân GBDT trên điểm embedding **không hơn** hợp nhất tuyến tính: `stack_llm` − `super_zs` = −0.0004 [−0.0010, +0.0002].
- Phần tăng của GBDT đến từ **exposure**: `stack_meta` − `stack_llm` = +0.0147 [+0.0142, +0.0153].

Mốc: `qwen3:frozen`; tổng mức tăng +0.0729. Reader: `cat:um_knn_rag`, trung bình 2 seed. Mọi bước lấy từ lần chạy v16b; tỷ trọng phụ thuộc thứ tự thêm thành phần.

Lời thoại gợi ý

Biểu đồ thác nước cho thấy mức tăng đến từ đâu. Khoảng 80% mức tăng đến từ các bước về embedding và reader: LSE, chuyên mục, reader, hợp nhất. 20% còn lại đến từ GBDT, nhưng phân tích kỹ cho thấy GBDT tự nó không hơn hợp nhất tuyến tính; phần tăng thật đến từ đặc trưng exposure.

Mô hình GBDT dựa vào đâu: split gain trên 500 cây

Tỷ trọng giảm hàm mục tiêu theo nhóm đặc trưng, cộng trên toàn bộ cây XGBoost:

Biến thể	scores	ctx	meta	pop	Đặc trưng có split gain cao nhất
stack_llm	66%	34%	–	–	cat:um_knn_rag, ctx_n_cand, ctx_slate_max, bge:um_frozen
stack_meta	**53%**	**27%**	**20%**	–	cat:um_knn_rag, ctx_n_cand, bge:um_frozen, ctx_slate_max, m_ctr
stack_pop	46%	22%	8%	24%	ctx_n_cand, cat:um_knn_rag, pop, popw_ctr_1h, bge:um_frozen



80% split gain của stack_meta đến từ điểm embedding và ngữ cảnh

- Đặc trưng dùng nhiều nhất là reader cat:um_knn_rag (9–13%). Với bài đã hiển thị nhiều mà ít click, m_ctr hạ hạng bài đó.
- Kích thước slate (ctx_n_cand) đứng đầu ở cả ba biến thể; bỏ nó làm điểm holdout giảm. Vai trò của nó cần kiểm tra thêm. Split gain mô tả mô hình đã khớp, không phải quan hệ nhân quả.

Lời thoại gợi ý

Split gain cho biết GBDT dựa vào đâu. Khoảng 80% đến từ điểm embedding và ngữ cảnh, tức là các thành phần LLM vẫn là xương sống. Kích thước slate quan trọng một cách khó giải thích; nhóm ghi nhận đây là điểm cần kiểm tra thêm, không diễn giải quá mức.

So sánh với kết quả đã công bố trên MIND-large

Mô hình	Nguồn / chế độ	AUC	MRR	nDCG@10
NRMS (GloVe-300)	nhiều bài báo, số thứ cấp	0.670–0.691	–	0.418–0.434
PLM-NR	Wu và cs., SIGIR 2021	0.7064	0.3539	0.4438
UNBERT	Zhang và cs., IJCAI 2021	0.7068	0.3568	0.4478
Fastformer + PLM-NR (ensemble)	đầu bảng xếp hạng, số thứ cấp	0.7268	–	–
`super_zs` (chỉ nội dung + lịch sử)	đề xuất, offline	0.6863	–	0.4373
`stack_meta` (+ exposure)	**đề xuất, offline**	**0.7013**	**0.3503**	**0.4516**
`stack_pop` (+ click trong ngày)	đề xuất, online	0.7196	0.3671	0.4731

Đọc bảng cho đúng

- Khác điều kiện: nhóm đo trên `MINDlarge_dev`; số công bố đo trên test của benchmark (nguồn thứ cấp).
- Hệ chỉ dùng nội dung và lịch sử (`super_zs`, `stack_llm`: AUC $\approx$ 0.686) nằm trong dải NRMS, thấp hơn PLM-NR khoảng 0.02 AUC.
- `stack_meta` ngang PLM-NR về AUC, cao hơn về nDCG@10, nhưng đọc thêm exposure: **không cùng bài toán**. `stack_pop` dùng click của chính ngày test nên không so trực tiếp.

Lời thoại gợi ý

Khi so với công bố, nhóm nói rất cẩn thận. Nếu chỉ dùng nội dung và lịch sử, hệ của nhóm nằm trong dải của NRMS và còn kém PLM-NR khoảng 0.02 AUC. stack_meta vượt PLM-NR về nDCG@10, nhưng nhờ thông tin exposure mà PLM-NR không dùng. Khoảng trống còn lại so với văn liệu nằm ở mô hình nội dung được tinh chỉnh end-to-end.

Triển khai: vector cache và GBDT so với PLM end-to-end

Tiêu chí	PLM tinh chỉnh end-to-end (PLM-NR, UNBERT)	Kiến trúc đề xuất (embedding cố định + GBDT)
Khi có bài mới	mã hóa bằng mô hình đang cập nhật; có thể phải huấn luyện lại	mã hóa mỗi bài **một lần**: ≈4 ms (BGE-large) đến 10 ms (Qwen3) trên T4
Khi phục vụ	chạy BERT/RoBERTa trên GPU	tích vô hướng trên vector đã lưu + duyệt cây GBDT
Độ trễ	phụ thuộc kích thước PLM, phần cứng	**chưa đo đầu-cuối**; ước tính vài ms mỗi slate (CPU)
Cold AUC	phụ thuộc mô hình đã tinh chỉnh	0.7248, không cập nhật trọng số encoder
nDCG@10	0.4438–0.4478 (số công bố)	0.4516 offline / 0.4731 online

Ý nghĩa thực tiễn và giới hạn

Toàn bộ quy trình MIND-large (14.085.557 cặp ứng viên test) chạy trong một notebook với 1 GPU T4 16 GB; RAM đỉnh đo được 21.2 GB (cần $\geq$ 24 GB). Độ trễ phục vụ mới là ước tính; cần đo đầu-cuối trước khi khẳng định khả năng triển khai.

Lời thoại gợi ý

Ưu điểm thực tế của kiến trúc là chi phí: mỗi bài chỉ mã hóa một lần, lúc phục vụ chỉ cần tích vô hướng và GBDT. Cả quy trình chạy trên một GPU T4. Nhóm chưa đo độ trễ đầu-cuối nên không khẳng định con số độ trễ; đó là việc cần làm tiếp.

Giới hạn của nghiên cứu

1. **Giao thức chọn mô hình:** $\tau = 0.80$ của validation có trọng số được chọn gần tỷ lệ click vào bài mới quan sát trên test (82.25%), vốn tính từ nhãn test. Cần thay bằng ước lượng không dùng nhãn.
2. **Một họ dữ liệu, một ngày test:** chỉ có MIND; dùng `*_dev` thay cho test của bảng xếp hạng; số công bố là số thứ cấp.
3. **Quy mô mô hình:** embedding lớn nhất 0.6B tham số, LLM sinh lớn nhất 1.7B; chưa thử embedding 4B–8B.
4. **Ngân sách tinh chỉnh:** H2 chỉ chạy trên MIND-small; tháp LoRA (H5) 800 bước, 1 seed, tập con 30.000 impression; chưa tinh chỉnh toàn phần trên MIND-large.
5. **Kết quả âm:** phần lớn đo trên MIND-small với một cấu hình; SID-GPT ngang vector ngẫu nhiên nên có thể do cài đặt.
6. **Độ bất định:** CI chỉ phản ánh nhiễu mẫu test. Nhiễu seed đo được: 0.007–0.014 nDCG@10 (MIND-small), 0.001–0.007 (reader trên MIND-large); nhiều hàng chỉ một seed.
7. **So sánh với công bố:** chưa chạy lại PLM-NR, UNBERT trên cùng `MINDlarge_dev`; chưa so với MINER, GLORY hay các phương pháp tin tức dùng LLM như ONCE.
8. **Chưa đo:** độ trễ đầu-cuối; các hướng SID-News và họ T.

Lời thoại gợi ý

Nhóm chủ động nêu giới hạn. Hai giới hạn quan trọng nhất: tham số 0.80 dùng thông tin tổng hợp từ test, và nhiều kết quả chỉ có một seed trong khi nhiễu seed khá lớn. Các kết quả âm cũng chủ yếu đo trên MIND-small với một cấu hình.

Kết luận: trả lời năm câu hỏi nghiên cứu

RQ1	Embedding cố định + cách tổng hợp tốt **ngang** NRMS, NAML, Fastformer huấn luyện lại (0.4094 so với NRMS refit 0.4078, CI chứa 0), hơn Fastformer refit (+0.0061): ngang, chưa vượt.
RQ2	Điểm nghẽn là **tầng tổng hợp lịch sử**: LSE tăng +0.011 đến +0.014 không cần tham số; bộ mã hóa lớn hơn gần như không giúp (+0.0015).
RQ3	Trong 14 họ đã đo: **2 thành công** (H8, H10), **2 có điều kiện** (F, H3), **10 không hiệu quả**, nhất là các hướng nén hoặc viết lại biểu diễn bằng LLM.
RQ4	Khi chỉ có điểm embedding, GBDT ≈ hợp nhất tuyến tính (−0.0004); GBDT có ích nhờ exposure (+0.0147). CV theo khối thời gian làm validation khớp test (lệch −0.0379 → −0.0072).
RQ5	Mở khóa 2 tầng cuối BGE-large không thu hẹp khoảng cách (+0.0005, n.s.; Cold AUC −0.0069); tháp LoRA không bổ sung cho bộ hợp nhất.

Ý chính. hệ thống ba tầng trên embedding cố định đạt **0.4516** nDCG@10 ở chế độ offline (+0.0729 so với mốc) và **0.4731** ở chế độ online, chạy trên 1 GPU T4; phần lớn mức tăng (khoảng 80%) đến từ cách dùng embedding và reader.

Lời thoại gợi ý

Tóm lại theo năm câu hỏi. Embedding cố định ngang baseline huấn luyện lại; điểm nghẽn là cách tổng hợp lịch sử; trong 14 họ chỉ 2 họ thành công rõ; GBDT chỉ có ích nhờ exposure; và tinh chỉnh một phần encoder chưa thu hẹp được khoảng cách với PLM tinh chỉnh end-to-end.

Ba điều rút ra và hướng nghiên cứu tiếp theo

Ba điều rút ra

1. Với tin tức, **cách gộp lịch sử đọc** quan trọng hơn kích thước hay loại bộ mã hóa.
2. Kỹ thuật dùng LLM để **nén hoặc viết lại** biểu diễn dễ làm mất chi tiết của bài mới, trong khi bài mới chiếm hơn 80% click.
3. **Cách đánh giá quyết định kết luận**: validation ấm và fold theo người dùng có thể biến một kỹ thuật vô ích thành "thành công".

Hướng tiếp theo

- Kiểm chứng trên dữ liệu có toàn văn bài viết (EB-NeRD).
- Thử embedding 4B–8B và tinh chỉnh LoRA trên toàn bộ MIND-large; chạy ≥ 3 seed.
- Ước lượng τ không dùng nhãn test; đo độ trễ đầu-cuối.
- Chạy đo SID-News và họ T; làm ablation riêng cho kích thước slate.

Lời thoại gợi ý

Ba điều rút ra là thông điệp nhóm muốn hội đồng nhớ. Hướng tiếp theo đều xuất phát từ giới hạn đã nêu: dữ liệu có toàn văn, mô hình lớn hơn với nhiều seed hơn, giao thức không dùng thông tin test, và đo các hướng còn dang dở.

XIN TRÂN TRỌNG CẢM ƠN!

Câu hỏi và thảo luận

Lời thoại gợi ý

Cảm ơn thầy cô và các bạn đã lắng nghe. Nhóm sẵn sàng trả lời câu hỏi; phần phụ lục có thuật ngữ, các câu hỏi thường gặp và danh mục các lần chạy.

Phụ lục · Thuật ngữ dùng trong bài

Impression	một lượt hiển thị: lịch sử đọc + danh sách ứng viên + nhãn click.
Bài mới / bài cũ	bài chưa / đã xuất hiện trong dữ liệu huấn luyện (cold / warm).
Mean pooling	vector người dùng là trung bình vector các bài đã đọc.
LSE, top-k	gộp độ tương đồng theo kiểu smooth-max hoặc trung bình k bài giống nhất (H8).
Reader	tầng nhẹ có huấn luyện đọc lịch sử trên embedding cố định; "theo ứng viên" nghĩa là ứng viên làm truy vấn attention (H10).
kNN RAG	cộng vào vector bài một phần vector của các bài gần nhất (H3).
Vector nối	ghép vector Qwen3 và BGE-large thành 2048 chiều.
Zero-shot	không huấn luyện thêm gì trên dữ liệu MIND.
Hợp nhất tuyến tính	cộng có trọng số các điểm đã chuẩn hóa (`super_*`).
GBDT stacker	cây quyết định tăng cường (XGBoost) học cách kết hợp các điểm và đặc trưng.
Exposure	thông tin hiển thị của bài lấy từ log, không dùng nhãn: tuổi bài, số lần hiển thị.
Online / offline	có / không dùng click của chính ngày test.
Time-block CV	chia fold theo khối thời gian liên tiếp thay vì theo người dùng.
CI ghép cặp	khoảng tin cậy của hiệu hai mô hình trên cùng các impression.
Bonferroni	hiệu chỉnh khi so sánh nhiều họ cùng lúc.
Nhiễu seed	chênh lệch giữa hai lần huấn luyện cùng cấu hình, khác seed.

Lời thoại gợi ý

Slide dự phòng: dùng khi cần giải thích nhanh một thuật ngữ.

Phụ lục · Câu hỏi có thể gặp (1/2)

Vì sao không tinh chỉnh LLM end-to-end như PLM-NR? Đã thử tinh chỉnh một phần theo đúng công thức PLM-NR (H12: mở khóa 2 tầng cuối BGE-large, có nhánh đối chứng đóng băng): $+0.0005$ (n.s.), Cold AUC -0.0069, không qua cổng $+0.006$ đặt trước. Tinh chỉnh toàn phần vượt khả năng 1 GPU T4; đây là hướng tiếp theo.

`stack_meta` vượt PLM-NR có công bằng không? Không cùng điều kiện: `stack_meta` đọc thêm exposure từ log, đo trên `MINDlarge_dev`; số PLM-NR là số công bố trên test benchmark. Phát biểu an toàn: hệ chỉ dùng nội dung + lịch sử (0.4373) còn thấp hơn PLM-NR (0.4438).

$\tau = 0.80$ có rò rỉ thông tin test không? Có dùng thông tin tổng hợp của test (tỷ lệ click vào bài mới), không dùng nhãn từng mẫu. Đây là giới hạn đã nêu; cách sửa là ước lượng τ từ tỷ lệ ứng viên mới, không cần nhãn.

Vì sao `stack_pop` không đem so với các bài báo? Nó dùng click của chính ngày test theo luồng, thông tin mà mô hình offline không có và không thể nộp lên bảng xếp hạng.

Semantic ID giảm -0.1011 có phải do lỗi? SID-GPT ngang đối chứng vector ngẫu nhiên (0.2898 so với 0.2897), nên khả năng cao mô hình sinh chưa học được; cần kiểm tra cài đặt trước khi kết luận về phương pháp.

Lời thoại gợi ý

Slide dự phòng cho phần hỏi đáp.

Phụ lục · Câu hỏi có thể gặp (2/2)

Khoảng tin cậy có tính nhiễu huấn luyện không? Không. CI ghép cặp chỉ phản ánh nhiễu mẫu test; nhiễu seed đo riêng (0.007–0.014 trên MIND-small, 0.001–0.007 cho reader trên MIND-large). Chênh nhỏ hơn mức đó giữa hai mô hình đã huấn luyện không được dùng để kết luận.

Sao không dùng embedding 4B–8B? Giới hạn GPU. Bằng chứng hiện có cho thấy encoder lớn hơn không tự động tốt hơn (BGE-large chỉ $+0.0015$ so với BGE-small; Qwen3-0.6B kém BGE-large $+0.0102$ khi làm đầu vào reader), nhưng chưa loại trừ được.

Vì sao GBDT không giúp khi chỉ có điểm embedding? Bốn trọng số tuyến tính đã khai thác hết thông tin của các điểm (-0.0004, n.s.); GBDT chỉ có ích khi có thông tin mới như exposure ($+0.0147$).

LSE đã so với attention học được, với NAML, Fastformer chưa? Có. Trên cùng vector cố định: reader kiểu NRMS, Fastformer, 4 truy vấn, theo ứng viên (slide "H8 so với attention học được"). Baseline đầy đủ NRMS, NAML, Fastformer: slide RQ1. Reader kiểu NAML trên vector cố định chưa chạy.

Kích thước slate quan trọng nhất có hợp lý không? Chưa rõ. Bỏ cột này làm điểm holdout giảm; có thể cây dùng nó làm ngữ cảnh để đổi cách kết hợp. Cần ablation riêng.

Đóng góp chính của đề tài là gì? (1) Đánh giá chặt 12 họ LLM 2024–2026 cho tin tức với baseline huấn luyện lại, CI ghép cặp và nhiễu seed; (2) chỉ ra điểm nghẽn là tầng tổng hợp lịch sử và hai cách sửa trên embedding cố định (LSE, reader theo ứng viên); (3) giao thức validation có trọng số bài mới + CV theo khối thời gian; (4) hệ ba tầng chạy trên 1 GPU T4.

Lời thoại gợi ý

Slide dự phòng cho phần hỏi đáp.

Phụ lục · Các lần chạy và nguồn số liệu

Lần chạy	Dữ liệu	Nội dung chính	Thời gian
V10	MIND-small	bộ đo gốc: NRMS, NAML, Fastformer, BGE zero-shot, popularity	–
v7	MIND-small	khoảng 16 họ kỹ thuật, khoảng 150 biến thể; baseline huấn luyện lại; thang ablation NRMS	7.52 giờ
v13	MIND-small	trường văn bản (F), lịch sử 100/200 click, đa sở thích (H11), Fastformer 2 seed + refit	8.22 giờ
v14	MIND-large	một encoder (Qwen3) và đủ kỹ thuật; bộ hợp nhất tuyến tính; tháp LoRA (H5)	2.90 giờ
v15	MIND-large	GBDT stacker (XGBoost GPU), đặc trưng exposure, encoder thứ hai BGE-large	2.73 giờ
v16b	MIND-large	CV theo khối thời gian, reader trên BGE-large và vector nối, đo RAM đỉnh (21.2 GB)	4.49 giờ
v17	MIND-large	mở khóa 2 tầng cuối BGE-large dưới reader (H12), nhánh đối chứng khớp cặp, cổng dừng	–

Mọi lần chạy là một notebook "Run All" trên Kaggle (Tesla T4 16 GB, mã dùng một GPU). Các bảng MIND-large trong bài lấy từ v16b, trừ các dòng đánh dấu (*) lấy từ v17.

Lời thoại gợi ý

Slide dự phòng: cho biết mỗi con số đến từ lần chạy nào.

Phụ lục · Tài liệu tham khảo chính

- F. Wu và cs. MIND: A Large-scale Dataset for News Recommendation. ACL 2020.
- C. Wu và cs. Neural News Recommendation with Multi-Head Self-Attention (NRMS). EMNLP-IJCNLP 2019.
- C. Wu và cs. Neural News Recommendation with Attentive Multi-View Learning (NAML). IJCAI 2019.
- C. Wu và cs. Fastformer: Additive Attention Can Be All You Need. arXiv 2021.
- C. Wu và cs. Empowering News Recommendation with Pre-trained Language Models (PLM-NR). SIGIR 2021.
- Q. Zhang và cs. UNBERT: User-News Matching BERT for News Recommendation. IJCAI 2021.
- T. Qi và cs. News Recommendation with Candidate-aware User Modeling (CAUM). SIGIR 2022.
- J. Li và cs. MINER: Multi-Interest Matching Network for News Recommendation. Findings of ACL 2022.
- Y. Cen và cs. Controllable Multi-Interest Framework for Recommendation (ComiRec). KDD 2020.
- O. Khattab, M. Zaharia. ColBERT. SIGIR 2020.
- A. Iana và cs. Simplifying Content-Based Neural News Recommendation. SIGIR 2023.
- P. BehnamGhader và cs. LLM2Vec. COLM 2024. Q. Liu và cs. LLMEmb. AAAI 2025.
- Y. He và cs. LLM2Rec. KDD 2025. Y. Zhang và cs. Qwen3 Embedding. arXiv 2025.
- C. Zhang và cs. EmbSum. RecSys 2024.
- Y. Xi và cs. Towards Open-World Recommendation with Knowledge Augmentation from LLMs (KAR). RecSys 2024.
- Q. Liu và cs. ONCE. WSDM 2024. Y. Yada, H. Yamana. Category Description by an LLM. arXiv 2024.
- D. Edge và cs. From Local to Global: A Graph RAG Approach. arXiv 2024.
- S. Wang và cs. Knowledge Graph RAG for LLM-based Recommendation. ACL 2025.
- S. Rajput và cs. Recommender Systems with Generative Retrieval (TIGER). NeurIPS 2023.
- W. Wang và cs. Learnable Item Tokenization for Generative Recommendation (LETTER). CIKM 2024.
- Y. Hou và cs. Generating Long Semantic IDs in Parallel (RPG). KDD 2025.
- Y. Hou và cs. LLMs are Zero-Shot Rankers for Recommender Systems. ECIR 2024. J. Gao và cs. LLM4Rerank. WWW 2025.
- Y. Wang và cs. Pre-train, Align, and Disentangle (PAD). SIGIR 2025.
- J. Kruse và cs. EB-NeRD: A Large-Scale Dataset for News Recommendation. RecSys Challenge 2024.

Lời thoại gợi ý

Slide dự phòng: danh sách tài liệu đã được đối chiếu tên, tác giả và hội nghị.